



Universidad
Rey Juan Carlos

Escuela Técnica Superior de Ingeniería Informática

RV-MAP: SISTEMA DE EVALUACIÓN DE TRANSITABILIDAD EN ZONAS CATASTRÓFICAS MEDIANTE VISIÓN AÉREA

Memoria del Trabajo Fin de Grado
en Ingeniería de Informática

Autor:

Alexandru Nicolas Untaru Ionescu

Tutor: Sergio Hernández García

Junio 2026

© 2026 Alexandru Nicolas Untaru Ionescu

Esta memoria de Trabajo de Fin de Grado está sujeta a una licencia
Creative Commons Atribución 4.0 Internacional (CC BY 4.0).

Para ver una copia legal de esta licencia, visite:
<http://creativecommons.org/licenses/by/4.0/>

Agradecimientos

En primer lugar, deseo expresar mi más profunda gratitud a mi tutor, Sergio Hernández García, de Trabajo de Fin de Grado, por su inestimable guía académica, su rigor y su supervisión constante. Sus correcciones y su visión técnica han sido fundamentales para elevar el estándar de esta memoria y estructurar el proyecto hasta su versión definitiva.

A José Manuel Payán del Río, por anclar este trabajo a la realidad del terreno. Gracias por enseñarme la verdadera magnitud y criticidad de las situaciones que se viven en escenarios de emergencia. Tus lecciones dotaron a este desarrollo de un propósito vital, recordando en todo momento que detrás de la computación hay un objetivo humano superior.

A mi familia, por su apoyo incondicional y su paciencia inagotable. Gracias por comprender las innumerables horas de aislamiento frente a la pantalla y por ser el soporte constante que me ha permitido culminar esta etapa universitaria.

A mis amigos, quienes se convirtieron de forma involuntaria en los primeros auditores del sistema. Gracias por vuestra disposición para escucharme hablar de código, por ayudarme a detectar fallos cuando la perspectiva del programador me impedía verlos, y por estar siempre ahí para celebrar cada pequeño avance del modelo.

Por último, me gustaría dedicar un agradecimiento especial a mi «yo» del pasado, al estudiante que decidió dar el primer paso y comenzar esta investigación. Gracias por tener la determinación de adentrarte en el desarrollo de esta arquitectura sin conocer en absoluto cuál sería el resultado final, demostrando que el verdadero valor del aprendizaje reside en atreverse a trazar una ruta cuando el mapa aún está en blanco.

*Alexandru Nicolas Untaru Ionescu
Madrid, 2026*

Resumen

Los desastres naturales, como el reciente fenómeno de la DANA en España, generan situaciones de emergencia crítica donde la rápida evaluación de daños y la movilidad operativa de los equipos de rescate son vitales. La presencia de infraestructuras colapsadas y carreteras bloqueadas por escombros dificulta enormemente el reconocimiento del terreno, retrasando la asistencia logística y médica.

Para abordar este desafío, el presente Trabajo de Fin de Grado plantea una investigación centrada en el análisis de modelos de visión artificial para la evaluación de entornos postdesastre. El núcleo del proyecto consiste en el entrenamiento y optimización de un modelo de segmentación de instancias utilizando la arquitectura de vanguardia YOLOv8, aplicando técnicas de *Transfer Learning* sobre el conjunto de datos RescueNet.

A lo largo de la investigación, el trabajo se enfoca en el análisis visual del modelo a través de la generación de mapas de colores semánticos. A partir de estas representaciones, se busca comprender a nivel espacial las zonas situadas alrededor de las clases detectadas, tales como edificios destruidos, vías despejadas o masas de agua, evaluando la gravedad y transitabilidad del terreno en base a las máscaras extraídas por la red neuronal.

Los resultados experimentales demuestran que el modelo alcanza una convergencia óptima en 150 épocas, gestionando las dificultades inherentes al sobreajuste y al desbalanceo de clases típico de las imágenes de catástrofes. En conclusión, esta investigación evidencia que una correcta interpretación de estos modelos visuales permite un mejor entendimiento topológico del entorno afectado, sentando las bases tecnológicas necesarias para optimizar la toma de decisiones y agilizar el movimiento de unidades especiales de intervención sobre el terreno.

Índice general

Agradecimientos	III
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.2.1. Objetivo general	2
1.2.2. Objetivos específicos	2
1.3. Estructura de la memoria	3
2. Estado del Arte	5
2.1. Visión Artificial y Aprendizaje Profundo	5
2.2. Algoritmos de Detección y Segmentación de Instancias	6
2.2.1. Evolución de la detección de objetos	6
2.2.2. Segmentación semántica y de instancias	6
2.2.3. Análisis crítico y alternativas arquitectónicas descartadas	7
2.2.4. La arquitectura YOLOv8	8
2.3. IA aplicada a la Gestión de Desastres	8
2.3.1. El rol de los UAV y las limitaciones satelitales	8
2.3.2. El conjunto de datos RescueNet	9
2.4. Navegación y Mapas de Costes Espaciales	9
2.4.1. Fundamentos de los Mapas de Coste	9
2.4.2. Campos de Potencial Artificial e Inflado de Obstáculos	9
3. Análisis	11
3.1. Modelado del problema	11
3.2. Requisitos del sistema	13
3.2.1. Requisitos funcionales	13
3.2.2. Requisitos no funcionales	13

3.3.	Metodología de desarrollo	14
3.4.	Modelo de Visión Artificial YOLOv8	14
3.4.1.	Extracción y agregación de características	14
3.4.2.	Generación de máscaras de segmentación	15
3.5.	Conjunto de datos RescueNet	16
3.5.1.	Origen y especificaciones del recurso	16
3.5.2.	Estadísticas y división de datos	16
3.5.3.	Muestrario visual y retos ópticos del entorno postdesastre	17
3.5.4.	Análisis de clases y entidades topológicas	19
3.5.5.	Desbalanceo de clases	20
4.	Diseño e Implementación	21
4.1.	Introducción al capítulo	21
4.2.	Justificación de Herramientas y Tecnologías	21
4.3.	Arquitectura del Software	22
4.4.	Desarrollo e Implementación Algorítmica	23
4.4.1.	Estrategias de Aumento de Datos y Mitigación de Sesgos	23
4.4.2.	Transformaciones espaciales y distorsiones topológicas	23
4.4.3.	Alteraciones radiométricas y de espectro cromático	24
4.4.4.	Composición algorítmica avanzada: Técnica Mosaic	24
4.4.5.	Inferencia y Segmentación de Instancias	25
4.4.6.	Tratamiento de Máscaras y Márgenes de Seguridad	25
4.4.7.	Gestión de Prioridades de Capas	25
4.4.8.	Generación del Mapa de Costes	26
4.5.	Visualización y Salida de Datos	27
4.6.	Despliegue Operativo e Interacción del Usuario	27
4.6.1.	Estructura de directorios y flujo de datos	28
4.6.2.	Interfaz de consola y parametrización	28
4.6.3.	Automatización y procesamiento en lote	29
5.	Experimentos y Pruebas	31
5.1.	Introducción al capítulo	31
5.2.	Entorno de pruebas y equipamiento físico	31
5.3.	Definición de métricas de evaluación	32
5.4.	Entrenamiento y validación del modelo	32
5.5.	Evaluación cualitativa del sistema visual	34

5.5.1.	Impacto visual de la convergencia del modelo	34
5.5.2.	Validación de la paleta cromática y carga cognitiva	35
5.5.3.	Auditoría visual y proyección de márgenes reales	38
5.6.	Análisis de rendimiento computacional	40
5.7.	Análisis de Casos Límite y Falsos Positivos	40
5.7.1.	Interferencias lumínicas y proyecciones de sombras densas	40
5.7.2.	Reflejos especulares y ceguera por saturación sensorial	41
5.7.3.	Variabilidad altimétrica y degradación de la escala espacial	41
5.7.4.	Alucinaciones algorítmicas y límites de optimización perceptiva	43
6.	Conclusiones y Trabajos Futuros	45
6.1.	Consecución de los objetivos	45
6.2.	Líneas de trabajo futuro	46
	Bibliografía	49
	A. Catálogo Extendido de Mapas de Transitabilidad	51
	B. Repositorio de Código y Acceso Abierto	55
B.1.	Acceso a la plataforma computacional	55
B.2.	Estructura del proyecto y reproducibilidad	55

Índice de tablas

1.	Comparativa cuantitativa de rendimiento entre las diferentes configuraciones del modelo en función de las épocas de entrenamiento	33
----	---	----

Índice de figuras

1.	Diagrama de casos de uso que ilustra el modelado del problema y la interacción del usuario con el sistema para la obtención de mapas de transitabilidad	12
2.	Muestrario visual extraído del conjunto de datos RescueNet. Se exponen cuatro cuadrantes ilustrando la alta variabilidad morfológica y los retos perceptivos del entorno operativo	18
3.	Histograma ilustrando la distribución y el desbalanceo del número de ejemplos por clase en el conjunto de datos RescueNet	20
4.	Diagrama de clases UML ilustrando los componentes principales del sistema y sus relaciones de dependencia	22
5.	Diagrama de secuencia UML que detalla el flujo temporal de llamadas a métodos desde la carga de la imagen hasta la exportación del mapa de transitabilidad	23
6.	Métricas de entrenamiento y validación del modelo YOLOv8 tras 150 épocas. Se observa la convergencia de la función de pérdida y la estabilización de la precisión media promedio	33
7.	Matriz de confusión obtenida sobre el conjunto de evaluación para las clases críticas de RescueNet	34
8.	Segmentación de instancias generada por el Modelo A tras 50 épocas de entrenamiento. Se aprecian contornos imprecisos y la fusión errónea de escombros cercanos	35
9.	Segmentación de instancias generada por el modelo óptimo. La arquitectura logra delimitar con alta fidelidad las siluetas individuales de vehículos y estructuras colapsadas	35
10.	Salida del sistema utilizando el esquema cromático bícromo térmico inicial: imagen original de prueba, izquierda, y matriz de transitabilidad renderizada en tonos azules y rojos, derecha	35
11.	Salida del sistema utilizando el esquema cromático optimizado para la reducción de carga cognitiva: imagen original de prueba, izquierda y matriz de transitabilidad renderizada en gradiente de blanco a rojo, derecha	36

12.	Catálogo de validación cualitativa del sistema RV-MAP. El panel exhibe seis escenarios operativos dispares donde los tensores de predicción se han transformado exitosamente en mapas de transitabilidad robustos. Las zonas blancas indican libre tránsito, mientras que la intensidad del canal rojo codifica la severidad y el radio de repulsión de los obstáculos detectados . .	37
13.	Salida del sistema gráfico RV-MAP utilizando la bandera de activación de auditoría visual: imagen original con perímetros expandidos, izquierda, y mapa cuantitativo de costes con gradiente cónico y marcadores de posición reales, derecha	38
14.	Galería en columna de auditoría visual del sistema RV-MAP. Se exhibe la proyección de contornos perimetrales sobre la topología original, izquierda, y sobre la matriz de costes renderizada, derecha	39
15.	Panel de auditoría de errores algorítmicos. Muestrario de casos límite operacionales donde las condiciones lumínicas, la escala y las oclusiones quiebran la precisión del sistema inferencial	42
16.	Evidencia de alucinaciones de clase provocadas por los límites de optimización perceptiva. Se contrastan fragmentos donde el modelo asigna erróneamente el grado de máxima penalización a zonas que pueden ser transitables	44
17.	Galería extendida de validación topológica, Parte I. Muestra de mapas bidimensionales generados por el sistema, contrastando la inferencia estándar con la auditoría de vehículos	52
18.	Galería extendida de validación topológica, Parte II	53

Índice de códigos

4.1. Lógica de preprocesamiento morfológico, asignación de pesos y sobreescritura de máscaras para la gestión de prioridades	26
4.2. Algoritmo de generación de la matriz de penalización decreciente basada en distancia euclidiana	26
4.3. Comando estándar de ejecución del sistema RV-MAP mediante interfaz de consola, ilustrando la asignación de rutas y la activación de la auditoría visual	28

Capítulo 1

Introducción

El presente capítulo constituye el punto de partida de este Trabajo de Fin de Grado, estableciendo el contexto fundamental y la justificación del proyecto. En primer lugar, se expone la motivación del proyecto, analizando la problemática operativa derivada de los desastres naturales y argumentando la necesidad técnica de automatizar la evaluación del terreno mediante visión artificial. A continuación, se definen de manera detallada el objetivo general y los objetivos específicos que guían el desarrollo, entrenamiento y evaluación del sistema propuesto. Finalmente, se detalla la estructura organizativa de la presente memoria.

1.1. Motivación

En las últimas décadas, el cambio climático y el calentamiento global han provocado una alteración evidente en la dinámica atmosférica, traduciéndose en un incremento de la frecuencia y severidad de los fenómenos meteorológicos extremos [15]. Esta problemática, de alcance global, se manifiesta a través de desastres naturales cuya magnitud excede a menudo la capacidad de respuesta de las infraestructuras actuales, derivando en crisis humanitarias y colapsos logísticos significativos.

Un ejemplo reciente y devastador de esta tendencia es la Depresión Aislada en Niveles Altos (DANA) que afectó a España en octubre de 2024. Este evento meteorológico se caracterizó por una virulencia extraordinaria, especialmente en la provincia de Valencia, donde localidades como Paiporta, Catarroja o Turís sufrieron inundaciones sin precedentes. Los registros oficiales señalaron acumulaciones de precipitación superiores a los 770 l/m² en menos de 24 horas [19]. Las consecuencias directas fueron trágicas, con más de 220 fallecidos y la destrucción o bloqueo de cientos de kilómetros de vías de comunicación, lo que aisló a poblaciones enteras durante las horas más críticas de la emergencia.

En el marco jurídico español, la gestión de estas crisis se articula a través de la Ley 17/2015 del Sistema Nacional de Protección Civil [11]. Esta normativa establece los protocolos para la evaluación de daños y la coordinación de los servicios de emergencia. Sin embargo, en la práctica, el procedimiento de reconocimiento del terreno depende todavía en gran medida de la inspección visual humana y del despliegue presencial de unidades terrestres. Esta metodología tradicional conlleva una latencia temporal crítica; la necesidad de recorrer físicamente zonas anegadas o bloqueadas por escombros impide obtener una visión de conjunto inmediata, retrasando la toma de decisiones estratégicas y la asistencia médica.

La introducción de Vehículos Aéreos No Tripulados (UAV, del inglés *Unmanned Aerial Vehicle*), comúnmente conocidos como drones, ha supuesto un avance en la captura de información visual desde perspectivas cenitales [3]. No obstante, la obtención de imágenes aéreas representa únicamente una solución parcial al problema. Una imagen digital es, en términos computacionales, una matriz de valores numéricos que representan los píxeles de color, y que requiere de un procesamiento posterior para su interpretación. Para que esta información resulte operativa en una misión de rescate, es imperativo realizar una transición desde la captura de datos hacia el análisis computacional de la información.

La visión artificial ofrece herramientas para abordar estas situaciones. Existe la necesidad técnica de transformar los píxeles en datos interpretables, ya sea por personas o máquinas, que permitan identificar, de manera automática y precisa, qué áreas del terreno son transitables y qué elementos constituyen obstáculos infranqueables. Mediante la clasificación y delimitación geométrica de los elementos presentes en el entorno catastrófico se pueden generar mapas de riesgo o de costes. Los algoritmos de planificación de rutas pueden hacer uso de estos mapas de riesgo para calcular trayectorias seguras y eficientes, optimizando la logística de emergencia y garantizando que los recursos de salvamento lleguen a su destino en el menor tiempo posible. Por tanto, en este trabajo se propone el desarrollo de un sistema computacional, denominado RV-MAP (*Rescue Vision Mapping*, o Sistema de Mapeo por Visión de Rescate), para automatizar dicha evaluación del terreno.

1.2. Objetivos

El propósito fundamental de esta investigación es dar respuesta a la problemática expuesta anteriormente, automatizando el reconocimiento del terreno para agilizar las labores de rescate. A continuación, se detalla la meta principal de este Trabajo de Fin de Grado, así como los hitos específicos requeridos para su consecución.

1.2.1. Objetivo general

El objetivo general de este proyecto es investigar y desarrollar un sistema basado en técnicas avanzadas de visión artificial que permita la evaluación automática de la transitabilidad y riesgo del terreno en entornos afectados por desastres naturales, partiendo del procesamiento de imágenes aéreas.

1.2.2. Objetivos específicos

Para alcanzar la meta general descrita, el desarrollo del proyecto se ha dividido en los siguientes pasos operativos:

- Estudiar y seleccionar una arquitectura de red neuronal orientada a la segmentación de instancias que ofrezca equilibrio entre precisión y eficiencia computacional para el procesamiento de imágenes cenitales.
- Localizar y seleccionar un conjunto de datos aéreo especializado en catástrofes naturales que permita el modelado de escenarios postdesastre.

- Entrenar el modelo de visión artificial seleccionado utilizando el conjunto de datos previo, con el fin de clasificar elementos críticos del terreno, tales como escombros, y calzadas despejadas.
- Diseñar e implementar un algoritmo para transformar los elementos segmentados en mapas cuantitativos de transitabilidad, aplicando técnicas de agregación de la información espacial para definir márgenes de seguridad alrededor de los obstáculos.
- Evaluar el rendimiento y la precisión del modelo entrenado empleando métricas de validación estandarizadas en el campo de la visión artificial.

1.3. Estructura de la memoria

Para facilitar la lectura y comprensión de este Trabajo de Fin de Grado, la presente memoria se ha estructurado de manera lógica y secuencial, dividiendo el contenido analítico e ingenieril en los siguientes capítulos:

- **Capítulo 2: Estado del Arte.** Se establece el marco teórico del proyecto. Se examina la evolución de la visión computacional y el aprendizaje profundo, analizando las arquitecturas de segmentación de instancias y justificando la idoneidad de la solución frente a alternativas tecnológicas vigentes. Asimismo, se contextualiza el uso de vehículos no tripulados en emergencias y la teoría de navegación espacial.
- **Capítulo 3: Análisis.** Se aborda la disección conceptual del problema, estableciendo los requisitos funcionales y no funcionales del sistema. Se detalla la topología interna del motor perceptivo seleccionado y se realiza un escrutinio exhaustivo del conjunto de datos aéreo empleado, exponiendo los severos retos ópticos propios del entorno postdesastre.
- **Capítulo 4: Diseño e Implementación.** Documenta la transición desde la teoría algorítmica hacia la construcción del software funcional. Se expone la arquitectura del sistema, las estrategias de mitigación de sesgos mediante aumento de datos, el desarrollo de la lógica tensorial para la extracción de mapas de costes y la configuración del despliegue operativo mediante interfaz de consola.
- **Capítulo 5: Experimentos y Pruebas.** Presenta la validación integral del sistema propuesto. Comprende la evaluación cuantitativa basada en métricas estandarizadas y la validación cualitativa sobre imágenes empíricas. Además, se incluye una auditoría visual de los contornos extraídos y un escrutinio crítico sobre los casos límite y falsos positivos operacionales.
- **Capítulo 6: Conclusiones y Trabajos Futuros.** Sintetiza los resultados obtenidos, evaluando formalmente el grado de cumplimiento de los objetivos planteados al inicio de la investigación, y propone nuevas líneas de desarrollo tecnológico para la evolución de la plataforma.
- **Anexo A: Catálogo de Mapas de Transitabilidad.** Recopila una galería ampliada de escenarios visuales procesados por la arquitectura, evidenciando el comportamiento de generalización del sistema RV-MAP sobre diversas infraestructuras.

- **Anexo B: Repositorio de Código y Acceso Abierto.** Proporciona las credenciales de acceso a la plataforma computacional pública, detallando la estructura del proyecto y los requerimientos de dependencias para garantizar la absoluta reproducibilidad del despliegue algorítmico.

Capítulo 2

Estado del Arte

El presente capítulo tiene como objetivo establecer el marco teórico y tecnológico sobre el cual se fundamenta esta investigación. Para comprender la solución propuesta, resulta imprescindible analizar la evolución de las tecnologías de visión artificial y el cambio de paradigma introducido por el *Deep Learning*. A continuación, se profundiza en las arquitecturas de detección y segmentación de instancias, con especial énfasis en la familia de modelos YOLO. Asimismo, se contextualiza la aplicación de la Inteligencia Artificial en la gestión de desastres naturales y se revisan los fundamentos de los mapas de transitabilidad en el ámbito de la robótica.

2.1. Visión Artificial y Aprendizaje Profundo

La visión artificial, entendida como la capacidad de un sistema computacional para extraer, procesar y comprender información a partir de imágenes digitales [6], ha experimentado una transformación radical en la última década. En sus inicios, la resolución de tareas de reconocimiento visual dependía exclusivamente de la ingeniería de características manual (*Feature Engineering*). En este enfoque, los investigadores diseñaban filtros para extraer bordes, texturas o formas geométricas. Algoritmos clásicos como las cascadas de Haar [27], SIFT (*Scale-Invariant Feature Transform*) [18] o HOG (*Histogram of Oriented Gradients*) [2] dominaron el panorama hasta principios de la década de 2010. Aunque estos métodos resultaban efectivos en entornos altamente controlados, presentaban una degradación de rendimiento severa al enfrentarse a variaciones de iluminación, oclusiones parciales o fondos complejos.

El verdadero punto de inflexión en la disciplina se consolidó con la maduración del aprendizaje profundo (*Deep Learning*) y, más concretamente, con las Redes Neuronales Convolucionales (CNN, del inglés *Convolutional Neural Networks*). A diferencia de los enfoques tradicionales, una CNN no requiere que un ingeniero programe qué características buscar en una imagen; la propia red aprende automáticamente una jerarquía de filtros óptimos a través del entrenamiento con grandes volúmenes de datos. La victoria de la arquitectura AlexNet en la competición ImageNet de 2012 [14] demostró la abrumadora superioridad de las CNN, sentando las bases para redes posteriores más profundas y eficientes como el grupo de geometría visual (VGG, del inglés *Visual Geometry Group*) y ResNet [10]. Esta última resolvió el problema del desvanecimiento del gradiente mediante conexiones resi-

duales, permitiendo entrenar redes de cientos de capas y habilitando la transición desde la simple clasificación de imágenes hacia la comprensión espacial de la escena.

2.2. Algoritmos de Detección y Segmentación de Instancias

Para que un vehículo no tripulado o un equipo de rescate pueda interpretar un entorno, no basta con saber qué objetos hay en una imagen, sino que es necesario conocer su ubicación exacta y su morfología. Históricamente, este reto se ha abordado mediante dos paradigmas analíticos diferenciados: la detección de objetos y la segmentación.

2.2.1. Evolución de la detección de objetos

Los sistemas de detección de objetos se dividen tradicionalmente en dos categorías: detectores de dos etapas y detectores de una etapa. Los modelos de dos etapas, como R-CNN [5], Fast R-CNN [4] y Faster R-CNN [24], operan generando primero una serie de regiones candidatas en la imagen y, posteriormente, clasificando cada una de estas regiones. Si bien estos modelos alcanzan una precisión alta, su arquitectura secuencial conlleva un coste computacional elevado, limitando su viabilidad en sistemas de tiempo real.

Como respuesta a esta limitación de latencia, surgieron los modelos de una etapa, como SSD (*Single Shot MultiBox Detector*) [16] y la familia YOLO (*You Only Look Once*) [23]. YOLO revolucionó la visión artificial al reformular la detección de objetos como un único problema de regresión unificado. Al dividir la imagen en una cuadrícula y predecir simultáneamente las cajas delimitadoras (*bounding boxes*) y las probabilidades de clase, YOLO logró velocidades de inferencia extraordinarias, democratizando el uso de la visión artificial en aplicaciones de robótica y videovigilancia.

2.2.2. Segmentación semántica y de instancias

A pesar de la velocidad de los detectores de una etapa, el uso de cajas rectangulares resulta insuficiente en entornos no estructurados como una zona de catástrofe. Un vehículo volcado o un rastro de escombros rara vez adopta una forma rectangular, por lo que una caja delimitadora incluiría inevitablemente píxeles de la carretera o del fondo, introduciendo un margen de error inasumible para la navegación.

La solución técnica a este problema es la segmentación. Por un lado, la segmentación semántica, popularizada por arquitecturas como FCN [17] o U-Net [25], clasifica cada píxel de la imagen en una categoría, pero no es capaz de distinguir entre diferentes objetos de la misma clase. Por otro lado, la segmentación de instancias combina lo mejor de ambos mundos: detecta cada objeto individualmente y genera una máscara de píxeles exacta que delimita su silueta real. Arquitecturas pioneras como Mask R-CNN [9] demostraron la viabilidad de este enfoque, aunque heredaban los problemas de latencia de los detectores de dos etapas.

2.2.3. Análisis crítico y alternativas arquitectónicas descartadas

Durante la fase de diseño e investigación del núcleo perceptivo para el sistema RV-MAP, se sometieron a evaluación diversas arquitecturas fundacionales en la disciplina de la visión artificial. Para justificar con rigor la adopción definitiva de YOLOv8, resulta imperativo exponer las razones técnicas y algorítmicas que motivaron el descarte de otros paradigmas hegemónicos. El análisis se centró fundamentalmente en dos alternativas prominentes: Mask R-CNN y U-Net.

Mask R-CNN y el cuello de botella computacional

Mask R-CNN se consolidó como la arquitectura pionera en demostrar la viabilidad operativa de la segmentación de instancias de alta fidelidad. Su diseño se estructura bajo un paradigma de dos etapas: una primera subred propone regiones candidatas en el espacio de la imagen y, subsecuentemente, ramas independientes clasifican, ajustan las delimitaciones y extraen las siluetas a nivel de píxel.

Si bien esta metodología secuencial arroja índices de precisión geométrica notables, su topología interna introduce una latencia inasumible para el contexto logístico de este proyecto. El procesamiento aislado de miles de regiones candidatas por cada fotograma satura el ancho de banda de la memoria de vídeo y dispara los tiempos de inferencia. En un escenario de emergencias operando bajo la doctrina de la Hora Dorada, donde el procesamiento debe ejecutarse a bordo de hardware de computación móvil o estaciones de control portátiles limitadas, la dependencia de un modelo tan pesado computacionalmente suponía un riesgo crítico. En consecuencia, Mask R-CNN fue descartado a favor de arquitecturas de una sola etapa capaces de procesar la matriz de la imagen en un flujo ininterrumpido.

U-Net y la limitación semántica frente a instancias múltiples

Por otro lado, se evaluó el uso de arquitecturas de convolución completa, con U-Net como principal exponente. Desarrollada inicialmente para el ámbito del diagnóstico biomédico, U-Net brilla por su capacidad para capturar el contexto global y preservar el detalle topológico mediante sus conexiones residuales.

El impedimento fundamental para su integración en el sistema propuesto no radicaba en su velocidad, sino en su naturaleza analítica. U-Net es un modelo de segmentación semántica pura. Esto implica que clasifica la imagen asignando una etiqueta a cada celda de la cuadrícula, pero es algorítmicamente incapaz de diferenciar objetos contiguos pertenecientes a la misma clase. En un panorama de destrucción, si dos vehículos volcados colisionan o una hilera de bloques de hormigón se apila sobre el asfalto, U-Net los percibe y fusiona como una única masa amorfa y continua.

Esta aglomeración impide aislar las entidades individuales, bloqueando la posibilidad de aplicar filtros morfológicos de seguridad concéntricos a cada obstáculo. La imposibilidad de contabilizar o rodear geométricamente cada escombros de forma autónoma inhabilitaba por completo las rutinas posteriores de generación de mapas de costes, forzando su exclusión del proyecto.

El salto cualitativo frente a modelos de una etapa previos

Incluso restringiendo la búsqueda a los modelos veloces de una sola etapa de la propia familia YOLO, las iteraciones anteriores (como YOLOv5 o YOLOv7) presentaban dependencias estructurales ancladas a las denominadas cajas ancla (*Anchor Boxes*). Este diseño de base obliga a predefinir proporciones espaciales fijas que el algoritmo intenta ajustar durante la inferencia. Frente a la morfología caótica, asimétrica y totalmente impredecible de una infraestructura colapsada, las cajas predefinidas inducían distorsiones severas en los contornos. Este obstáculo justificó la necesidad de buscar una arquitectura capaz de predecir bordes de forma dinámica y desvinculada de estructuras rígidas precalculadas.

2.2.4. La arquitectura YOLOv8

Lanzada en 2023 por Ultralytics, YOLOv8 [12] representa el estado del arte en modelos de visión unificados. Esta arquitectura evoluciona respecto a sus predecesoras al adoptar un enfoque sin anclajes (*Anchor-free*), eliminando la necesidad de definir cajas delimitadoras predeterminadas y reduciendo drásticamente la carga de parámetros.

En su variante de segmentación (*YOLOv8-seg*), la arquitectura incorpora múltiples módulos C2f (*Cross Stage Partial Bottleneck with 2 convolutions*) para mejorar la extracción de características, y divide su cabecera en dos ramas operativas: una para la detección y clasificación, y otra rama prototipo para la generación de máscaras. Esta dualidad permite calcular máscaras de alta fidelidad en tiempo real. Su versatilidad para el aprendizaje por transferencia (*transfer learning*) permite la adaptación del modelo a dominios visuales específicos.

2.3. IA aplicada a la Gestión de Desastres

La evaluación de daños mediante sensores remotos ha sido un área de investigación activa durante décadas. Sin embargo, la resolución de las imágenes y la calidad de los modelos analíticos han supuesto cuellos de botella históricos.

2.3.1. El rol de los UAV y las limitaciones satelitales

Históricamente, la gestión de desastres se ha apoyado en imágenes satelitales. Iniciativas como el conjunto de datos xBD [7] han impulsado la creación de modelos capaces de evaluar daños estructurales desde la órbita terrestre. No obstante, las imágenes satelitales presentan inconvenientes críticos durante una emergencia operativa: una frecuencia de paso o tiempo de adquisición que puede demorar días, baja resolución espacial y una alta susceptibilidad a la cobertura nubosa, frecuente durante tormentas y huracanes.

La generalización de los Vehículos Aéreos No Tripulados (UAV) [3] ha mitigado estas deficiencias. Un dron puede desplegarse en minutos bajo la capa de nubes, capturando ortofotos de alta resolución geométrica, alcanzando una escala de centímetros por píxel. Este nivel de detalle permite identificar fisuras, evaluar la profundidad del agua y distinguir el tipo de escombros que bloquea una vía, información invisible para un satélite.

2.3.2. El conjunto de datos RescueNet

A pesar de la disponibilidad de drones, el entrenamiento de redes neuronales requiere conjuntos de datos masivos y rigurosamente etiquetados. En el contexto de las catástrofes naturales, el caos visual, el solapamiento de estructuras y las variaciones extremas de color e iluminación dificultan enormemente la recopilación de datos de calidad.

En este ecosistema destaca *RescueNet* [22], un conjunto de datos de alta resolución diseñado específicamente para la segmentación semántica y de instancias postdesastre. Este conjunto de datos proporciona anotaciones exhaustivas a nivel de píxel para clases fundamentales en misiones de rescate, como agua, edificios destruidos, vehículos, escombros y carreteras.

2.4. Navegación y Mapas de Costes Espaciales

El reconocimiento visual del terreno es ineficaz si no se traduce a un formato comprensible para los algoritmos de navegación robótica y planificación de rutas, como A* o Dijkstra.

2.4.1. Fundamentos de los Mapas de Coste

En robótica, el entorno se modela mediante mapas de costes. Un mapa de costes proyecta el entorno físico sobre una cuadrícula bidimensional, asignando a cada celda un valor numérico escalar. Este valor representa la transitabilidad o el *coste* de atravesar dicha coordenada. Típicamente, los espacios libres, como el asfalto limpio, reciben un peso de cero o cercano a cero, mientras que los obstáculos físicos, como escombros o vehículos, reciben un peso máximo, actuando como paredes infranqueables.

2.4.2. Campos de Potencial Artificial e Inflado de Obstáculos

En un entorno postdesastre, la incertidumbre espacial es elevada y las estructuras colapsadas pueden presentar inestabilidad. Por ello, la robótica móvil emplea la teoría de Campos de Potencial Artificiales [13]. Esta técnica asume que los objetivos actúan como fuerzas de atracción, mientras que los obstáculos emiten fuerzas de repulsión invisibles que decaen con la distancia.

Para implementar este comportamiento de seguridad en un mapa de costes, se aplica una técnica denominada *inflado de obstáculos* (*Obstacle Inflation*). En lugar de mantener bordes duros y tajantes alrededor de un escombros, se aplica un operador convolucional, como un filtro Gaussiano o un Kernel cónico lineal. Este proceso diluye el peso de penalización hacia el exterior del obstáculo, creando un gradiente de peligro. De este modo, los algoritmos de enrutamiento son obligados a mantener un radio de seguridad prudencial, prefiriendo trazar rutas por el centro de las avenidas y evitando pasar a escasos centímetros de escombros que podrían representar un riesgo de derrumbe.

Capítulo 3

Análisis

El presente capítulo detalla la fase de análisis del proyecto, cuyo objetivo es proporcionar una descripción exhaustiva del problema a resolver y de las necesidades técnicas identificadas. En las siguientes secciones se define el modelado del problema desde una perspectiva operativa, se enumeran los requisitos funcionales y no funcionales del sistema, se describe la metodología empleada para el desarrollo y se realiza un estudio detallado del conjunto de datos externo utilizado para el entrenamiento del modelo.

3.1. Modelado del problema

El escenario operativo se define por la necesidad crítica que tienen los equipos de emergencia, logística y rescate de conocer, en el menor tiempo posible, qué rutas permiten el paso de vehículos terrestres y qué zonas se encuentran bloqueadas por agentes externos destructivos, como escombros, inundaciones severas o vehículos siniestrados. La problemática central de este trabajo radica en la ineficiencia y latencia de los métodos actuales para evaluar la transitabilidad del terreno tras un desastre natural de gran magnitud.

Desde el punto de vista analítico, el problema fundamental consiste en la transformación de una fuente de información visual y no estructurada en una herramienta de toma de decisiones logísticas. El flujo de trabajo tradicional obliga a un operador humano a visualizar horas de grabaciones aéreas, interpretar los obstáculos y comunicar por radio o trazar manualmente las rutas viables. Este proceso presenta una carga cognitiva inasumible durante una crisis, generando cuellos de botella que retrasan la intervención médica y el suministro de recursos básicos.

Para solventar esta deficiencia, el sistema a modelar debe automatizar la extracción de valor semántico. El problema subyacente consiste en proyectar una matriz de entrada bidimensional, esto es, la imagen digital capturada por el dron compuesta por píxeles sin clasificar, sobre una nueva matriz de salida de idénticas dimensiones, donde cada coordenada posea un valor de coste o riesgo asociado.

En este modelo conceptual, el entorno físico se divide en tres categorías analíticas mutuamente excluyentes:

- **Zonas de libre tránsito:** Áreas que conservan su integridad estructural, como carreteras intactas o asfalto despejado, y cuyo coste de navegación debe ser mínimo.

- **Zonas de obstáculo estricto:** Elementos físicos infranqueables, tales como edificios colapsados, acumulación de escombros o vehículos volcados, cuyo coste de navegación debe ser infinito o máximo.
- **Zonas de incertidumbre o riesgo atenuado:** El espacio de transición entre un obstáculo y una vía libre. El problema exige que el riesgo no desaparezca de forma binaria en el borde del escombros, sino que exista un margen de seguridad que penalice la proximidad a estructuras potencialmente inestables.

Para ilustrar las interacciones del sistema con los actores involucrados, se ha definido un modelo basado en casos de uso. El actor principal del sistema es el *Operador de Emergencias*, quien suministra las imágenes cenitales obtenidas en campo. El sistema debe procesar estas entradas, clasificar las entidades topológicas del entorno y devolver un mapa de transitabilidad comprensible.




Figura 1: Diagrama de casos de uso que ilustra el modelado del problema y la interacción del usuario con el sistema para la obtención de mapas de transitabilidad

Como se detalla en la figura 1, el actor principal, definido como el Operador de Emergencias o el Equipo de Rescate, interactúa de forma directa con la frontera del sistema a través de tres casos de uso fundamentales, los cuales dan cobertura estricta a los requisitos funcionales previamente elicitados:

- **Cargar imágenes aéreas:** Representa la entrada de datos brutos procedentes de la telemetría de los vehículos aéreos no tripulados.
- **Generar mapa de transitabilidad:** Constituye el núcleo de valor del sistema. El usuario solicita la evaluación visual del entorno y el software delega el procesamiento de forma transparente al caso de uso subordinado «*Evaluar terreno mediante IA*». Esta relación de inclusión garantiza que el operador no necesite conocimientos técnicos en tensores o redes neuronales para operar la herramienta.
- **Exportar mapa de costes:** Habilita la extracción de la cartografía procesada hacia los dispositivos móviles del personal desplegado sobre el terreno, completando el ciclo de inteligencia logística.

Para formalizar la especificación del diseño, se ha empleado el Lenguaje Unificado de Modelado (UML, por sus siglas en inglés, Unified Modeling Language).

3.2. Requisitos del sistema

Para garantizar que la solución desarrollada sea operativa y cumpla con las expectativas técnicas, se han definido una serie de requisitos divididos en funcionales y no funcionales. Cada uno de estos puntos guía el proceso de diseño y validación posterior.

3.2.1. Requisitos funcionales

Los requisitos funcionales definen las acciones específicas que el software debe ser capaz de realizar:

- **RF-1: Procesamiento de imágenes aéreas.** El sistema debe permitir la entrada y procesamiento de imágenes capturadas desde perspectivas cenitales mediante drones.
- **RF-2: Segmentación de clases críticas.** El modelo debe identificar y delimitar con precisión las siluetas de, al menos, tres categorías fundamentales: carreteras transitables, escombros y zonas de agua.
- **RF-3: Generación de mapas de coste.** El sistema debe ser capaz de transformar las predicciones visuales en una representación que asigne pesos de transitabilidad al terreno.
- **RF-4: Visualización de resultados.** El software debe generar una salida gráfica comprensible donde se diferencien claramente los niveles de riesgo mediante un código de colores.

3.2.2. Requisitos no funcionales

Los requisitos no funcionales especifican las propiedades y restricciones bajo las cuales el sistema debe operar:

- **RNF-1: Eficiencia temporal.** Dado el contexto de emergencia, el tiempo de procesamiento por imagen debe ser reducido para permitir una evaluación casi en tiempo real.
- **RNF-2: Portabilidad y compatibilidad.** El sistema debe desarrollarse utilizando lenguajes y librerías estándar en el sector de la inteligencia artificial, facilitando su ejecución en diferentes entornos hardware.
- **RNF-3: Precisión geométrica.** El sistema debe priorizar la delimitación exacta de los bordes de los obstáculos sobre la simple detección, para minimizar el riesgo de colisión en futuras rutas.

3.3. Metodología de desarrollo

Para la ejecución de este Trabajo de Fin de Grado se ha optado por un enfoque de desarrollo iterativo. Esta decisión metodológica se fundamenta en la naturaleza investigadora del proyecto; el entrenamiento de redes neuronales y el diseño de filtros espaciales requieren una experimentación empírica continua, evaluación de métricas y un ajuste constante de parámetros.

El flujo de trabajo se estructuró en iteraciones flexibles orientadas a la resolución secuencial de problemas técnicos. Esta adaptabilidad metodológica ha resultado un factor clave para el éxito del proyecto, ya que ha permitido absorber los retrasos inherentes a la fase de investigación. Ante los imprevistos y bloqueos técnicos surgidos durante el entrenamiento del modelo YOLOv8 [12], el enfoque iterativo permitió readaptar la planificación temporal y centrar los esfuerzos en la optimización de los mapas de costes sin paralizar el desarrollo global del sistema.

3.4. Modelo de Visión Artificial YOLOv8

Para cumplir con el requisito de eficiencia temporal en escenarios de emergencia establecido previamente, la selección del núcleo algorítmico constituye una decisión de diseño crítica. Tras evaluar el estado del arte, se ha seleccionado la arquitectura YOLOv8 en su variante de segmentación de instancias, desarrollada por Ultralytics [12]. Esta elección se justifica por su capacidad para procesar imágenes en tiempo real sin comprometer la precisión geométrica, superando las limitaciones de latencia inherentes a los modelos de segmentación de dos etapas convencionales.

Aunque los fundamentos de la familia YOLO se introdujeron en el marco teórico, el diseño del presente sistema requiere una comprensión profunda de cómo esta versión específica aborda la tarea de la segmentación. La arquitectura interna de YOLOv8 se divide en tres componentes principales: la red troncal, el cuello y la cabecera dual de predicción.

3.4.1. Extracción y agregación de características

La primera fase del procesamiento visual recae en la red troncal, responsable de extraer las características topológicas de la imagen. El modelo emplea una estructura convolucional avanzada que optimiza el flujo de los gradientes durante el entrenamiento y reduce la carga computacional. Esta red procesa la imagen a diferentes escalas, capturando tanto patrones de bajo nivel, como los bordes de una carretera, como estructuras semánticas complejas, tales como edificios colapsados o vehículos volcados.

Posteriormente, la información extraída se transfiere al cuello de la red, implementado mediante una arquitectura de agregación de caminos. Este componente fusiona las características de diferentes resoluciones espaciales. Dicha fusión resulta indispensable en el dominio de las catástrofes naturales, donde el modelo debe detectar y segmentar simultáneamente objetos diminutos, como fragmentos de escombros esparcidos, y entidades masivas, como cuerpos de agua o infraestructuras enteras.

3.4.2. Generación de máscaras de segmentación

El avance tecnológico más relevante de esta arquitectura para el cálculo de los mapas de transitabilidad reside en su cabecera de segmentación. YOLOv8 adopta un enfoque libre de anclajes espaciales predeterminados y aborda la segmentación de instancias descomponiendo el problema en dos tareas paralelas que operan de forma simultánea, fundamentadas en los principios de la arquitectura YOLACT (*You Only Look At CoefficientTs*).

Por un lado, una primera rama predictiva calcula las cajas delimitadoras de los objetos detectados y sus probabilidades de pertenecer a una clase topológica específica. Por otro lado, la generación de la silueta exacta se delega a un mecanismo eficiente que se bifurca en dos subprocesos matriciales:

- **Rama de prototipos (P):** Consiste en una red totalmente convolucional que genera un conjunto de k máscaras base de alta resolución, denominadas prototipos, para toda la imagen global, independientemente de los objetos individuales presentes.
- **Rama de coeficientes (C):** Para cada objeto detectado, el modelo predice un vector numérico escalar compuesto por k coeficientes de máscara. Estos coeficientes codifican el peso o la contribución que cada prototipo global tendrá sobre la silueta final de dicho objeto.

Para aislar la silueta definitiva de un obstáculo, el modelo computa una combinación lineal entre los mapas de los prototipos y los coeficientes predichos exclusivamente para esa instancia en particular. La máscara final M de una entidad se calcula mediante la siguiente expresión algebraica:

$$M = \sigma \left(\sum_{i=1}^k c_i P_i \right)$$

Donde c_i representa el coeficiente individual predicho para el objeto, P_i es el mapa del prototipo correspondiente generado sobre la imagen completa, y σ denota la función de activación sigmoide. Esta función es crítica, ya que proyecta los valores continuos resultantes al rango $[0, 1]$, binarizando los píxeles para diferenciar estrictamente entre el fondo y la entidad.

Este método de combinación matricial evita el elevado coste computacional de procesar segmentaciones pesadas de forma secuencial y permite delimitar los bordes exactos de los escombros de forma casi instantánea, una sola inferencia. En consecuencia, proporciona la base geométrica idónea y rigurosa sobre la cual el sistema RV-MAP puede aplicar posteriormente el algoritmo de inflado cónico requerido para establecer los márgenes de navegación robótica.

3.5. Conjunto de datos RescueNet

El desarrollo y entrenamiento de un modelo de segmentación de instancias requiere un gran volumen de datos rigurosamente etiquetados. En el contexto de este proyecto, la adquisición empírica de imágenes aéreas de zonas catastróficas resultaba inviable. Por ello, el núcleo del aprendizaje del sistema depende de un conjunto de datos externo especializado denominado *RescueNet* [22]. Este recurso es fundamental para que el análisis sea autocontenido y el modelo pueda generalizar en escenarios reales de catástrofe, proporcionando la base estadística necesaria para el entrenamiento de la arquitectura de visión artificial.

3.5.1. Origen y especificaciones del recurso

RescueNet es un conjunto de datos público de alta resolución diseñado específicamente para evaluar el daño estructural tras desastres naturales. Las imágenes que componen este recurso fueron capturadas tras el impacto del huracán Michael en 2018 en el estado de Florida, Estados Unidos, empleando para ello drones de consumo de la plataforma DJI Mavic Pro. Este detalle es relevante para el análisis, ya que garantiza que el sistema se entrena con la calidad óptica y la perspectiva cenital que encontraría un equipo de rescate real en el despliegue de campo.

Las ortofotos están capturadas con una resolución del orden de centímetros por píxel, conocida como distancia de muestreo del suelo o GSD por sus siglas en inglés, lo que permite diferenciar texturas complejas, como la separación geométrica entre un vehículo siniestrado y los escombros que lo rodean. El uso de este conjunto de datos conlleva el reconocimiento de la investigación previa realizada por sus autores, por lo que la presente memoria referencia formalmente el artículo científico original que documenta el proceso de adquisición y etiquetado [22].

3.5.2. Estadísticas y división de datos

El conjunto de datos analizado consta de un total de 4494 imágenes de alta resolución. Para asegurar un proceso de aprendizaje robusto y una evaluación posterior imparcial, los datos se encuentran estructurados en tres subconjuntos metodológicos:

- **Entrenamiento:** Representa aproximadamente el 80 % del volumen total, utilizado para el ajuste de los pesos de la red neuronal.
- **Validación:** Un 10 % destinado a la monitorización del aprendizaje y ajuste de hiperparámetros.
- **Evaluación:** El 10 % final, reservado para la comprobación del rendimiento sobre imágenes nunca antes vistas por el modelo.

3.5.3. Muestrario visual y retos ópticos del entorno postdesastre

Para comprender la complejidad del problema y de aplicar técnicas de visión artificial a este, resulta indispensable examinar la naturaleza visual de las ortofotos que conforman el conjunto *RescueNet*. El procesamiento de un entorno urbano tras el paso de un huracán difiere drásticamente de la segmentación en entornos industriales controlados. Las imágenes capturadas por el UAV introducen un alto grado de entropía visual, derivado de la propia naturaleza destructiva del evento.

A nivel óptico e interpretativo, el sistema debe enfrentarse a tres retos fundamentales presentes en las capturas:

- **Oclusiones severas y solapamiento estructural:** A diferencia de un escenario urbano estándar donde las entidades mantienen una separación espacial predecible, el entorno postdesastre se caracteriza por el colapso de las geometrías. Los tejados se proyectan sobre las vías, los árboles ocultan parcial o totalmente a los vehículos, y la amalgama de escombros disimula las fronteras físicas originales de las calles.
- **Similitud espectral (Camuflaje visual):** Uno de los mayores escollos algorítmicos radica en la ausencia de contraste cromático. El hormigón pulverizado, los restos de fachadas y el asfalto de las carreteras comparten una firma de color grisácea casi idéntica. El modelo no puede depender del color, sino que debe inferir la clase basándose estrictamente en patrones de textura y formas geométricas.
- **Condiciones de iluminación extremas:** Al tratarse de capturas realizadas en exteriores bajo condiciones meteorológicas inestables, las imágenes presentan variaciones severas de exposición. Las sombras arrojadas por las edificaciones supervivientes actúan como ruido visual, oscureciendo fragmentos de la calzada, mientras que la luz solar directa incidiendo sobre láminas de agua estancada genera reflejos especulares que ciegan temporalmente los sensores ópticos.

Para ilustrar esta complejidad, la figura 2 expone un panel comparativo con recortes representativos del conjunto de datos, evidenciando las discrepancias topológicas entre las distintas clases que el sistema debe discriminar.



a) Vía de tránsito despejada. Los límites del asfalto son regulares y la textura es homogénea, facilitando la extracción de la silueta



b) Calzada bloqueada por escombros y vehículos. Se aprecia el solapamiento de formas irregulares y la similitud espectral con el suelo



c) Inmueble con destrucción total. La geometría ortogonal original ha desaparecido, generando un patrón visual altamente entrópico



d) Zona con anegación hídrica severa. Los reflejos ópticos y la turbidez del agua ocultan la topología del terreno subyacente

Figura 2: Muestrario visual extraído del conjunto de datos RescueNet. Se exponen cuatro cuadrantes ilustrando la alta variabilidad morfológica y los retos perceptivos del entorno operativo

El adiestramiento del núcleo perceptivo frente a este muestrario caótico es lo que garantiza que la posterior generación de gradientes de seguridad y mapas de costes posea la robustez requerida para su despliegue en campo, evitando que el sistema quede inoperativo ante el menor cambio en las condiciones lumínicas del escenario real.

3.5.4. Análisis de clases y entidades topológicas

El etiquetado semántico original de *RescueNet* es exhaustivo y contempla once categorías diferenciadas del entorno postdesastre: 1) Fondo, 2) Agua, 3) Edificio sin daños, 4) Edificio con daños menores, 5) Edificio con daños mayores, 6) Edificio totalmente destruido, 7) Carretera despejada, 8) Carretera bloqueada, 9) Vehículo, 10) Árbol y 11) Piscina.

Para el modelado del problema de este proyecto, el análisis integra las edificaciones como elementos clave, no solo por su naturaleza física, sino por su valor estratégico en misiones de salvamento. Las categorías críticas seleccionadas son:

- **Carreteras transitables:** Superficies asfaltadas libres de obstrucciones. Representan el nivel de coste mínimo en el modelo, siendo el objetivo primordial para la planificación de rutas.
- **Obstáculos dinámicos y bloqueos:** Elementos como vehículos o escombros que han invadido la calzada. Se modelan con un coste máximo e infinito, ya que impiden físicamente el paso de los equipos terrestres.
- **Cuerpos de agua:** Zonas inundadas que, además de ser infranqueables, representan un riesgo de seguridad adicional por la posible inestabilidad del terreno subyacente.
- **Edificaciones y estructuras:** Esta categoría es fundamental para el contexto de la misión. Se analizan bajo una doble vertiente:
 - *Desde la transitabilidad:* Actúan como obstáculos estáticos permanentes. Un edificio en buen estado no supone una penalización extra en las vías colindantes, mientras que un edificio destruido suele ser el origen de la clase escombros en la calzada.
 - *Desde la prioridad de rescate:* La detección de edificios con daños mayores o destrucción total permite al sistema identificar zonas de alta prioridad. Aunque no se pueda circular a través de ellos, su localización orienta a los algoritmos de enrutamiento para que las trayectorias calculadas finalicen o pasen lo más cerca posible de estos puntos de interés donde la probabilidad de encontrar civiles afectados es máxima.

3.5.5. Desbalanceo de clases

El análisis exhaustivo de *RescueNet* revela el principal desafío técnico del proyecto: el profundo desbalanceo estadístico de sus clases. En la naturaleza de un evento catastrófico, la proporción del terreno que se mantiene intacto, como una carretera transitable, es estadísticamente muy inferior a la superficie cubierta por agua, escombros o vegetación.




Figura 3: Histograma ilustrando la distribución y el desbalanceo del número de ejemplos por clase en el conjunto de datos RescueNet

Este desbalanceo inherente en los datos de entrada supone un problema crítico para el entrenamiento de redes neuronales convolucionales. Si no se aborda adecuadamente en la fase de diseño, el modelo de visión artificial tenderá a desarrollar un sesgo algorítmico, sobreajustándose a las clases mayoritarias, como el fondo o los escombros, e ignorando las clases minoritarias pero críticas, como las vías despejadas. Por tanto, la identificación de este sesgo estadístico durante el análisis establece un requisito técnico vinculante para la fase de implementación: la necesidad de configurar funciones de pérdida ponderadas o aplicar técnicas de optimización que equilibren el aprendizaje del modelo YOLOv8 [12] durante el entrenamiento.

Capítulo 4

Diseño e Implementación

4.1. Introducción al capítulo

El presente capítulo detalla el proceso de transformación de los requisitos analíticos en una solución software completamente funcional. En primer lugar, se justifican las herramientas y librerías seleccionadas para el desarrollo. A continuación, se presenta la arquitectura general del sistema apoyada en diagramas de modelado unificado, los cuales ilustran tanto la estructura estática como el flujo de ejecución dinámico. Finalmente, se describe en profundidad la implementación de los algoritmos, desglosando el código fuente y la formulación responsable de la generación de los mapas de costes espaciales.

4.2. Justificación de Herramientas y Tecnologías

El desarrollo del sistema se ha cimentado sobre un ecosistema de tecnologías de código abierto, estandarizadas en la industria de la visión artificial y el cálculo numérico:

- **Python:** Lenguaje de programación principal del proyecto [26]. Su elección se justifica por su naturaleza multiparadigma y su amplio uso en el sector de la inteligencia artificial.
- **PyTorch:** Marco de trabajo de aprendizaje profundo [20]. Actúa como el motor de cálculo tensorial en la unidad de procesamiento gráfico (GPU), sobre el cual se ejecuta el entrenamiento y la inferencia de la arquitectura YOLOv8.
- **OpenCV:** Librería de visión artificial [1]. Se ha utilizado exhaustivamente para las tareas de preprocesamiento, manipulación de canales de color y operaciones morfológicas sobre las máscaras generadas.
- **NumPy:** Paquete fundamental para la computación científica en Python [8]. Constituye la base para la creación de la cuadrícula del mapa de costes, permitiendo realizar operaciones matriciales de manera eficiente.
- **PlantText:** Herramienta basada en la nube para la generación automática de diagramas UML a partir de lenguaje de marcado estructurado [21]. En este proyecto se ha utilizado para el diseño riguroso y la vectorización de la arquitectura del software.

4.3. Arquitectura del Software

El sistema ha sido diseñado bajo una arquitectura modular y secuencial, conocida comúnmente como *pipeline* de procesamiento. Esta separación de responsabilidades garantiza que el módulo de visión artificial sea independiente del módulo de cálculo lógico, facilitando futuras actualizaciones.

El flujo de información atraviesa tres etapas principales:

1. **Módulo de entrada e Inferencia:** Se encarga de cargar la imagen aérea, redimensionarla al tamaño de entrada óptimo y ejecutar los pesos entrenados del modelo para extraer las máscaras de segmentación.
2. **Módulo de Transformación Espacial:** Recibe los tensores con las predicciones y proyecta las siluetas sobre un espacio matricial bidimensional vacío, asignando pesos de transitabilidad.
3. **Módulo de Inflado y Generación de Costes:** Aplica filtros espaciales sobre la matriz de obstáculos para crear gradientes de penalización, generando el renderizado visual y exportando el mapa.

Para formalizar este diseño, el **Diagrama de Clases** ilustra la estructura estática orientada a objetos del sistema. Se han definido clases gestoras principales, destacando los módulos responsables de la carga del modelo algorítmico y los encargados de la lógica matricial.




Figura 4: Diagrama de clases UML ilustrando los componentes principales del sistema y sus relaciones de dependencia

Por otro lado, el **Diagrama de Secuencia** modela el comportamiento dinámico del flujo de ejecución temporal. En él se detalla cómo el bloque de control principal solicita la imagen, desencadena la predicción y orquesta el traspaso de datos hacia el generador de mapas hasta la obtención del resultado gráfico final.




Figura 5: Diagrama de secuencia UML que detalla el flujo temporal de llamadas a métodos desde la carga de la imagen hasta la exportación del mapa de transitabilidad

4.4. Desarrollo e Implementación Algorítmica

El reto técnico de este proyecto recae en la traducción de predicciones probabilísticas a un modelo de navegación física. A continuación se detalla la implementación en código de los distintos submódulos algorítmicos.

4.4.1. Estrategias de Aumento de Datos y Mitigación de Sesgos

Tal y como se diagnosticó durante el escrutinio de las estadísticas demográficas del conjunto *RescueNet*, el agudo desbalanceo entre las clases mayoritarias, tales como la destrucción estructural total o el fondo inerte, y las minoritarias, vías despejadas, constituía un riesgo severo de sobreajuste. Para contrarrestar este fenómeno indeseado y dotar al motor neuronal de una capacidad de generalización superior frente a escenarios inéditos, se implementó una agresiva estrategia de aumento de datos (*Data Augmentation*) durante la fase de adiestramiento.

Esta técnica operativa consiste en aplicar transformaciones estocásticas y espaciales a las imágenes originales antes de inyectarlas en el flujo de la red, generando un caudal inagotable de variaciones ópticas a partir del mismo archivo base. De este modo, la arquitectura no memoriza píxeles estáticos, sino que se ve forzada a asimilar los patrones morfológicos subyacentes de cada obstáculo.

4.4.2. Transformaciones espaciales y distorsiones topológicas

El primer bloque de alteraciones busca romper la dependencia del algoritmo respecto a la orientación y la escala de los objetos capturados por la lente del UAV:

- **Inversiones especulares (*Flip*):** Se aplican espejados horizontales y verticales de forma aleatoria sobre la matriz original. Un vehículo volcado debe ser reconocido y clasificado como obstáculo independientemente de si su estructura apunta hacia el norte o hacia el sur en el plano cenital.

- **Traslaciones y escalados dinámicos:** El encuadre de la imagen se desplaza y se amplía o reduce artificialmente. Esta compresión de la cuadrícula obliga a la red a detectar escombros tanto en primeros planos detallados como en visiones panorámicas alejadas, mitigando el problema de la variabilidad altimétrica de los vuelos analizado en capítulos posteriores.
- **Rotaciones afines:** Girar la matriz fotográfica en ángulos arbitrarios impide que los tensores convolucionales se acomoden a líneas rectas perfectamente alineadas con los ejes cartesianos, un escenario completamente utópico tras un colapso estructural urbano.

4.4.3. Alteraciones radiométricas y de espectro cromático

Para inmunizar al sistema de percepción frente a los caprichos meteorológicos y la variabilidad de las lentes de los distintos fabricantes de drones, se inyectaron perturbaciones directas sobre los canales de color:

- **Desplazamiento en el espacio HSV:** Se alteran estocásticamente los valores de Matiz (*Hue*), Saturación (*Saturation*) y Brillo (*Value*). Esta mutación simula capturas bajo cielos plomizos, atardeceres anaranjados, presencia de polvo en suspensión o mediodías deslumbrantes.
- **Inyección de ruido artificial:** La superposición de ruido estático sobre el lienzo prepara a la red para procesar transmisiones de vídeo degradadas por interferencias electromagnéticas o pérdida de paquetes de datos en la telemetría del enlace inalámbrico.

4.4.4. Composición algorítmica avanzada: Técnica Mosaic

La innovación más contundente aplicada en el conducto de entrenamiento para erradicar la ceguera espacial es la técnica de ensamblaje *Mosaic*, impulsada de forma nativa por la arquitectura YOLOv8. Durante la carga de los lotes de procesamiento (*batches*), el algoritmo selecciona cuatro ortofotos distintas del repositorio, recorta fragmentos aleatorios de cada una y las fusiona intersecándolas en un único lienzo compuesto.

Esta amalgama sintética obliga a la red a procesar cuatro contextos urbanos diametralmente distintos de forma simultánea. Como resultado colateral altamente beneficioso, la técnica reduce drásticamente la escala de los objetos individuales y multiplica exponencialmente la densidad de entidades por fotograma, forzando a los filtros de extracción de características a afinar su agudeza perceptiva. La conjunción de estas estrategias de distorsión diluyó el riesgo del sesgo demográfico original, permitiendo que la curva de validación lograra asimilar las vías transitables y converger de forma estable.

4.4.5. Inferencia y Segmentación de Instancias

Una vez el modelo procesa la imagen a través de la librería Ultralytics, devuelve un conjunto de resultados compuesto por cajas delimitadoras y máscaras binarias. El algoritmo implementado filtra en primer lugar aquellas predicciones cuyo umbral de confianza sea inferior al 15 % (`conf=0.15`), eliminando detecciones ruidosas pero manteniendo la sensibilidad necesaria para detectar escombros pequeños.

Las máscaras segmentadas, que residen originalmente en la memoria de la tarjeta gráfica como tensores, son transferidas a la memoria principal (`cpu().numpy()`) y redimensionadas mediante OpenCV a la resolución exacta de la imagen de entrada, sentando la base espacial para el mapa.

4.4.6. Tratamiento de Máscaras y Márgenes de Seguridad

Para los obstáculos dinámicos, como vehículos abandonados o vegetación caída, no basta con proyectar su silueta exacta. El sistema aplica una operación de dilatación morfológica para crear un margen de seguridad inicial.

En la implementación, cuando se detectan las clases críticas (como la clase 6 correspondiente a vehículos en el dominio de la aplicación), se genera un núcleo estructural elíptico y se aplica la función `cv2.dilate`. Este proceso expande artificialmente el área ocupada por la carrocería en la matriz booleana, asegurando que los algoritmos de enrutamiento eviten rozar el obstáculo.

4.4.7. Gestión de Prioridades de Capas

Al proyectar múltiples máscaras sobre una misma cuadrícula bidimensional, se produce un solapamiento ineludible. Si una carretera pasa por debajo de un edificio colapsado, la matriz final debe reflejar el obstáculo y no la vía. Para solucionar este conflicto, se ha implementado un sistema de diccionarios de pesos (`PESOS`) y lógica de prioridades.

Listado de código 4.1: Lógica de preprocesamiento morfológico, asignación de pesos y sobreescritura de máscaras para la gestión de prioridades

```
# Dilatacion previa especifica para contornos de vehiculos
if id_clase == 6:
    radio_exp = 1
    d = 2 * radio_exp + 1
    kernel_circular = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (d
        , d))
    mask_bool = cv2.dilate(mask_bool.astype(np.uint8),
        kernel_circular, iterations=1).astype(bool)

# Registro de la capa aislada para la auditoria visual
if id_clase == 6:
    mascara_vehiculos[mask_bool] = 255

# Asignacion del coste base en la matriz
peso_asignado = PESOS.get(id_clase, 0.5)
mapa_pesos_nitido[mask_bool] = peso_asignado

# Identificacion de entidades que requieren inflado de seguridad conico
if id_clase in [5, 6, 9]:
    mascara_para_inflar[mask_bool] = 1.0

# Registro estricto de vias libres de obstaculos
if peso_asignado < 0.4:
    mascara_transitable[mask_bool] = True
```

Como se observa en el Listado 4.1, las clases destructivas sobrescriben cualquier valor de transitabilidad previo en el arreglo bidimensional `mapa_pesos_nitido`

4.4.8. Generación del Mapa de Costes

El núcleo diferencial del sistema reside en el algoritmo de inflado. Una representación binaria resulta ineficaz para la robótica, que requiere un gradiente de penalización asociado al riesgo de derrumbe. Para ello, se ha desarrollado un generador matricial de *Kernels* cónicos lineales.

Listado de código 4.2: Algoritmo de generación de la matriz de penalización decreciente basada en distancia euclidiana

```
def obtener_kernel_conico(radio):
    # Crea una matriz cuadrada donde los valores decaen linealmente
    # desde el centro
    y, x = np.ogrid[-radio:radio+1, -radio:radio+1]
    distancia = np.sqrt(x**2 + y**2)
    kernel = np.maximum(0, 1 - (distancia / radio))
    return kernel
```

El Listado 4.2 muestra cómo la librería NumPy calcula la distancia euclidiana desde el centro geométrico hasta el perímetro definido por el `radio`. Posteriormente, la función `cv2.filter2D` convoluciona este Kernel sobre los obstáculos extraídos, logrando que el coste decaiga linealmente hacia el exterior. Por último, una operación `np.maximum()` fusiona este gradiente con la matriz base, garantizando que ninguna zona colindante tenga un riesgo menor al dictaminado por la proximidad al escombros.

4.5. Visualización y Salida de Datos

El último eslabón de la arquitectura es la transformación de la matriz de coma flotante a un formato visualmente interpretable para el operador humano. Los valores numéricos, acotados en el rango $[0, 1]$, se escalan a un espacio de color BGR de 8 bits. Durante las fases iniciales de diseño, se evaluó una representación basada en contrastes térmicos de tonalidades azules y rojas; sin embargo, el análisis del flujo de trabajo determinó que este esquema cromático imponía una carga cognitiva excesiva bajo condiciones operativas de alto estrés.

Para mitigar esta fatiga visual y optimizar la toma de decisiones, se implementó un rediseño hacia un gradiente continuo de intensidades de blanco a rojo. Mediante la manipulación algebraica de los canales de la imagen, las zonas de libre tránsito, coste cercano a 0, se renderizan en color blanco puro, maximizando el contraste. Por el contrario, a medida que la penalización del terreno aumenta, el algoritmo intensifica progresivamente la saturación del canal rojo, permitiendo al operador asimilar la gravedad del obstáculo de forma instintiva e inmediata.

Además, respondiendo a los requisitos operativos de campo, se ha integrado una función de auditoría visual que puede ser conmutada mediante el parámetro `--show`. Al activarse, la librería OpenCV calcula los contornos externos de las clases dinámicas como los vehículos (`cv2.findContours`) y traza líneas discontinuas amarillas sobre ambas imágenes, original y mapa. Finalmente, una operación `np.hstack` concatena horizontalmente ambos lienzos, exportando un archivo gráfico integral (*mapchart*) que permite al equipo de mando contrastar el cálculo frente a la realidad física capturada por el dron.

El impacto práctico de este rediseño cromático, así como la utilidad operativa de la función de auditoría visual en escenarios reales, se exponen y evalúan empíricamente mediante pruebas de campo en la sección de evaluación cualitativa del **Capítulo 5**.

4.6. Despliegue Operativo e Interacción del Usuario

Para que la arquitectura algorítmica desarrollada trascienda el ámbito del prototipo de laboratorio y se consolide como una herramienta logística operativa en el terreno, resulta indispensable definir el mecanismo de interacción entre el operador de emergencias y el núcleo de software. En escenarios de alta criticidad, las interfaces gráficas pesadas (GUI, del inglés *Graphical User Interface*) pueden consumir recursos valiosos de la memoria y presentar problemas de compatibilidad en terminales portátiles. Por ello, se ha optado por implementar una Interfaz de Línea de Comandos (CLI, por sus siglas en inglés *Command Line Interface*) ligera, robusta y altamente parametrizable.

4.6.1. Estructura de directorios y flujo de datos

El aislamiento del entorno de ejecución es vital para evitar la pérdida de información o la sobrescritura accidental de telemetría original. El sistema RV-MAP impone una jerarquía de directorios estricta que guía el flujo de los tensores de imagen desde su entrada hasta su exportación gráfica. El espacio de trabajo se divide en tres repositorios fundamentales:

- **Directorio de entrada (/input_dron):** Actúa como la bandeja de entrada del sistema. El operador o el técnico de comunicaciones descarga en esta ruta las ráfagas de ortofotos crudas directamente desde la tarjeta de almacenamiento del vehículo aéreo.
- **Directorio de Exportación (/output_mapas):** Constituye el sumidero final. El software crea y deposita en esta ubicación las representaciones matriciales renderizadas (los mapas de costes) sin alterar bajo ninguna circunstancia los ficheros originales.
- **Bóveda de Pesos (/modelos):** Una carpeta protegida de solo lectura donde se alojan los archivos con extensión `.pt` (*PyTorch Tensors*). Estos archivos contienen los millones de parámetros sinápticos ajustados durante las 150 épocas de adiestramiento, listos para ser cargados en la tarjeta gráfica.

4.6.2. Interfaz de consola y parametrización

La ejecución del núcleo de procesamiento se invoca a través de un único comando en la terminal del sistema operativo, acompañado de argumentos o banderas condicionales (*flags*) que alteran el comportamiento del flujo lógico. Esta aproximación permite a los equipos automatizar la ejecución mediante *scripts* de procesamiento por lotes si fuera necesario.

El diseño del módulo de interacción se apoya en la librería estándar `argparse` de Python, la cual dota al sistema de robustez frente a errores de sintaxis del usuario. A continuación, se ilustra la instrucción típica de arranque introducida por el operador de campo:

Listado de código 4.3: Comando estándar de ejecución del sistema RV-MAP mediante interfaz de consola, ilustrando la asignación de rutas y la activación de la auditoría visual

```
python main_rvmap.py --input ./input_dron --model ./
modelos_entrenados/yolov8_optimo.pt --show
```

Como se documenta en el Listado 4.3, la ordenación del flujo depende de las siguientes variables de entorno:

- **--input:** Indica al motor de visión la ruta exacta donde debe iniciar el rastreo de imágenes nuevas. El algoritmo explorará este directorio iterativamente, garantizando el procesamiento secuencial de toda la misión de vuelo.
- **--model:** Dirige la red hacia el fichero de tensores preentrenados específico que debe instanciar en la memoria de vídeo. Esta modularidad permite al operador intercambiar cerebros algorítmicos en segundos, por ejemplo, cargar un modelo entrenado para inundaciones frente a uno optimizado para terremotos sin necesidad de reescribir una sola línea del código fuente.

- `--show`: Bandera de ejecución condicional de vital importancia logística. Su mera inclusión en la instrucción de arranque ordena al motor de renderizado la proyección paralela de la máscara de auditoría visual, contornos amarillos segmentados, sobre el lienzo original. Su omisión en el comando descarta el procesamiento de esta capa gráfica, ahorrando milisegundos de latencia computacional por fotograma si el Puesto de Mando solo requiere la matriz de transitabilidad cruda.

4.6.3. Automatización y procesamiento en lote

Un requisito ineludible en operaciones de salvamento es la mitigación de la intervención humana reiterativa. Si una pasada del UAV recopila trescientas fotografías ortogonales, resulta inasumible exigir al usuario que ejecute el comando ilustrado en el Listado 4.3 de forma individual para cada captura.

Para erradicar este cuello de botella, se ha programado una rutina de extracción iterativa global. Una vez invocado el comando principal, el entorno inicializa la carga pesada de los tensores de YOLOv8 en la memoria VRAM una única vez. Posteriormente, una estructura de bucle inyecta fotograma tras fotograma en la red, aplicando los filtros de dilatación morfológica, disipando los gradientes cónicos euclidianos y volcando el resultado final en el directorio de exportación. Esta automatización transforma el sistema en una cadena de montaje de inteligencia espacial ininterrumpida, permitiendo al operador dedicar su carga cognitiva a la interpretación del plano y a la organización táctica de las rutas, en lugar de a la gestión informática de los archivos.

Capítulo 5

Experimentos y Pruebas

5.1. Introducción al capítulo

El presente capítulo expone la metodología de validación aplicada al sistema de visión artificial desarrollado. El objetivo principal es demostrar, mediante pruebas empíricas, la viabilidad teórica y operativa de los algoritmos descritos en los capítulos anteriores. Para ello, se detalla el equipamiento físico utilizado, se definen las métricas de evaluación estándar y se exponen los resultados obtenidos, divididos en un análisis cuantitativo del modelo neuronal y una evaluación cualitativa de los mapas de transitabilidad. Finalmente, se realiza un estudio del rendimiento computacional y una discusión crítica sobre las limitaciones detectadas.

5.2. Entorno de pruebas y equipamiento físico

Para garantizar la reproducibilidad de los experimentos y justificar los tiempos de inferencia computacional, resulta imperativo detallar el entorno de ejecución utilizado. Las pruebas y el entrenamiento del modelo neuronal se han llevado a cabo en un equipo informático con las siguientes especificaciones técnicas:

- **Unidad Central de Procesamiento (CPU):** Intel Core i5-11400H de 6 núcleos y 12 hilos de ejecución, con una frecuencia de reloj base de 2.7 GHz y una frecuencia turbo máxima de 4.5 GHz, perteneciente a la arquitectura Tiger Lake-H.
- **Memoria de Acceso Aleatorio (RAM):** 16 GB de memoria síncrona de tipo DDR4 operando a una velocidad de 3200 MHz.
- **Unidad de Procesamiento Gráfico (GPU):** NVIDIA GeForce RTX 3050 Ti Laptop GPU con 4 GB de memoria dedicada de tipo GDDR6, un reloj de núcleo configurado a 1500 MHz y un límite de potencia de diseño térmico de 75 W. Esta unidad resulta fundamental para la aceleración del cálculo tensorial requerido por la arquitectura YOLOv8.
- **Entorno de software:** Sistema operativo Windows 11, lenguaje de programación Python en su versión 3.10 y la librería PyTorch configurada con soporte para la plataforma de computación paralela CUDA 11.8.

5.3. Definición de métricas de evaluación

La evaluación del rendimiento de un modelo de segmentación de instancias requiere el uso de métricas que cuantifiquen la precisión de las detecciones frente a las anotaciones reales del conjunto de datos. En este proyecto se han empleado las siguientes métricas estandarizadas:

Intersección sobre Unión (IoU)

Esta métrica, también conocida como índice de Jaccard, evalúa la superposición espacial entre la silueta o máscara predicha por el modelo y la máscara real etiquetada en el conjunto de datos. Se define mediante la siguiente expresión:

$$IoU = \frac{\text{Área de Intersección}}{\text{Área de Unión}} = \frac{VP}{VP + FP + FN}$$

Donde VP representa los verdaderos positivos, FP los falsos positivos y FN los falsos negativos.

Precisión y Exhaustividad

La precisión mide la proporción de detecciones correctas sobre el total de predicciones realizadas por el modelo. Por su parte, la exhaustividad, conocida en la literatura técnica como *recall*, cuantifica la proporción de objetos reales que el modelo ha sido capaz de localizar satisfactoriamente.

$$\text{Precisión} = \frac{VP}{VP + FP}$$

$$\text{Exhaustividad} = \frac{VP}{VP + FN}$$

Precisión Media Promedio (mAP)

La Precisión Media Promedio, o mAP por sus siglas en inglés, es la métrica global de rendimiento de la arquitectura YOLOv8. Representa el área bajo la curva de precisión-exhaustividad calculada para múltiples umbrales de confianza y promediada sobre todas las clases del modelo. En las arquitecturas de segmentación, esta métrica se desglosa de forma independiente para las cajas delimitadoras, denotada con una letra B, y para las máscaras de píxeles, denotada con una letra M.

5.4. Entrenamiento y validación del modelo

La fase cuantitativa de las pruebas se centra en el entrenamiento de la arquitectura sobre el conjunto de datos RescueNet. Durante este proceso, se monitorizaron las curvas de pérdida para garantizar que el modelo convergiera adecuadamente sin incurrir en un sobreajuste a los datos de entrenamiento.




Figura 6: Métricas de entrenamiento y validación del modelo YOLOv8 tras 150 épocas. Se observa la convergencia de la función de pérdida y la estabilización de la precisión media promedio

Como se documenta en la figura 6, las funciones de pérdida correspondientes a las cajas delimitadoras y a la segmentación geométrica disminuyen de forma progresiva tanto en el subconjunto de entrenamiento como en el de validación. La ausencia de divergencias en las etapas tardías confirma un aprendizaje saludable libre de sobreajuste.

Para determinar el impacto del tiempo de cómputo en la capacidad predictiva, se llevó a cabo un estudio comparativo entrenando cuatro configuraciones de la misma arquitectura bajo diferentes límites de iteraciones. Los resultados numéricos obtenidos en el subconjunto de evaluación se detallan en la tabla 1.

Tabla 1: Comparativa cuantitativa de rendimiento entre las diferentes configuraciones del modelo en función de las épocas de entrenamiento

Configuración	Épocas	mAP50 (B)	mAP50-95 (B)	mAP50 (M)	mAP50-95 (M)
Modelo A	50	0.69	0.49	0.69	0.46
Modelo B	125	0.71	0.53	0.70	0.48
Modelo C (Óptimo)	150	0.72	0.54	0.72	0.49
Modelo D	200	0.72	0.53	0.72	0.50

El análisis de la matriz de confusión generada por la configuración óptima de 150 épocas ha permitido validar la robustez del sistema frente al desbalanceo estadístico de las clases. Los resultados indican que el modelo aísla con una Precisión Media Promedio de 0.72 las máscaras de las carreteras transitables, superando las interferencias visuales del entorno.



Figura 7: Matriz de confusión obtenida sobre el conjunto de evaluación para las clases críticas de RescueNet

Como se aprecia en la figura 7, el mayor desafío de clasificación radica en una leve superposición estadística entre las clases correspondientes a edificios con daños mayores y edificios totalmente destruidos, provocada por la similitud estructural de ambas entidades cuando se analizan exclusivamente desde una perspectiva aérea cenital.

5.5. Evaluación cualitativa del sistema visual

Más allá de las métricas numéricas, la utilidad del sistema propuesto reside en su capacidad para ofrecer representaciones espaciales interpretables por los equipos de gestión de emergencias. En esta fase práctica, se procesaron imágenes inéditas comparando el impacto visual de los diferentes estadios de entrenamiento del modelo y validando la posterior generación de los mapas de costes.

5.5.1. Impacto visual de la convergencia del modelo

La superioridad estadística del modelo óptimo se traduce directamente en una mejora operativa durante el reconocimiento del terreno. Para ilustrar este fenómeno, se ha sometido una imagen de prueba a la inferencia de las distintas arquitecturas evaluadas, contrastando los resultados del entrenamiento temprano frente a la parametrización final.




Figura 8: Segmentación de instancias generada por el Modelo A tras 50 épocas de entrenamiento. Se aprecian contornos imprecisos y la fusión errónea de escombros cercanos




Figura 9: Segmentación de instancias generada por el modelo óptimo. La arquitectura logra delimitar con alta fidelidad las siluetas individuales de vehículos y estructuras colapsadas

La inspección comparativa de las figuras 8 y 9 demuestra la evolución del aprendizaje espacial. Las configuraciones tempranas omiten escombros de menor tamaño o tienden a fusionar las siluetas de vehículos colindantes en una única masa continua. Por el contrario, el modelo óptimo ajustado durante 150 épocas delimita de forma estricta los bordes de cada entidad independiente con precisión centimétrica, lo que reduce drásticamente la introducción de falsos positivos en el cálculo de las trayectorias de rescate.

5.5.2. Validación de la paleta cromática y carga cognitiva

Para validar empíricamente la hipótesis de usabilidad planteada en la fase de diseño, se sometió el sistema a un análisis comparativo secuencial utilizando los dos esquemas de color desarrollados. El objetivo es comprobar cómo influye la representación cromática en la velocidad de interpretación del riesgo por parte del operador humano.



Figura 10: Salida del sistema utilizando el esquema cromático bícromo térmico inicial: imagen original de prueba, izquierda, y matriz de transitabilidad renderizada en tonos azules y rojos, derecha

Como se documenta en la figura 10, la primera aproximación de diseño empleó un contraste térmico de azules para las vías libres y rojos para los obstáculos. La inspección cualitativa revela que este modelo sobresatura el lienzo analítico al introducir ruido visual coloreado sobre las áreas completamente despejadas. En un entorno real de catástrofe, esta representación incrementa de forma innecesaria la fatiga visual del operario debido a la densidad de estímulos innecesarios.

Para mitigar esta problemática y reducir la carga cognitiva bajo condiciones de alto estrés, se evaluó el escenario utilizando la paleta optimizada de intensidades, la cual se detalla a continuación.




Figura 11: Salida del sistema utilizando el esquema cromático optimizado para la reducción de carga cognitiva: imagen original de prueba, izquierda y matriz de transitabilidad renderizada en gradiente de blanco a rojo, derecha

El contraste analítico con la figura 11 confirma la superioridad operativa del rediseño. Al mantener las zonas de libre tránsito en color blanco limpio, los estímulos cromáticos rojos se concentran exclusivamente sobre las estructuras colapsadas, los escombros y sus respectivos márgenes de peligro cónicos. Esta simplificación del entorno gráfico permite al operador asimilar la gravedad y la geometría de las obstrucciones de forma instintiva e inmediata, acelerando el trazado de rutas de evacuación.

Para consolidar esta validación y demostrar la robustez del sistema bajo diversas condiciones operativas, a continuación se expone una batería visual, figura 12 de escenarios empíricos heterogéneos. La inspección de estas nuevas capturas permite atestiguar el comportamiento, la precisión geométrica y la capacidad de generalización del modelo óptimo frente a múltiples topologías urbanas afectadas por el desastre natural.



a) Intersección vial curva rodeada de estructuras colapsadas. El algoritmo aísla con éxito la trayectoria asfáltica, aplicando el gradiente de penalización de forma estricta sobre las zonas de escombros perimetrales



b) Tramo de carretera perimetral. Se aprecia una delimitación geométrica fluida de la calzada continua, excluyendo de forma contundente el fondo topológico complejo y degradado de los márgenes



c) Entorno residencial severamente dañado. El sistema detecta y perfila los inmuebles destruidos, zonas de saturación roja máxima, preservando intacta la red de movilidad adyacente que permanece operativa



d) Infraestructura de puente cruzando una lámina de agua. El modelo discrimina perfectamente el tablero de la plataforma estructural frente al lecho acuático y la biomasa acumulada en la ribera



e) Vía principal obstaculizada por un vehículo pesado. La matriz de costes aísla el obstáculo dinámico en pleno trazado, generando el margen de seguridad cónico indispensable para evitar colisiones robóticas



f) Topología de ramificación compleja junto a un edificio en pie. La red convolucional extrae la silueta asimétrica del pavimento libre, demostrando alta fidelidad en la definición de contornos irregulares

Figura 12: Catálogo de validación cualitativa del sistema RV-MAP. El panel exhibe seis escenarios operativos dispares donde los tensores de predicción se han transformado exitosamente en mapas de transitabilidad robustos. Las zonas blancas indican libre tránsito, mientras que la intensidad del canal rojo codifica la severidad y el radio de repulsión de los obstáculos detectados

5.5.3. Auditoría visual y proyección de márgenes reales

Para optimizar la logística de movilidad de las unidades de emergencia, resulta imperativo conocer no solo la estimación del riesgo, sino la huella física exacta de los obstáculos. Por ello, se ha integrado una función de auditoría visual conmutable que permite renderizar el área real ocupada por entidades críticas, como los vehículos abandonados.

Aunque el algoritmo asigne preventivamente un gradiente de alta penalización a la zona colindante para asegurar una navegación autónoma segura, la visualización explícita del contorno original proporciona al equipo humano un dato empírico. Esta capa gráfica permite a los operadores contrastar el margen de seguridad sugerido frente al bloqueo físico real, facilitando una interpretación más clara y precisa del terreno para autorizar maniobras tácticas excepcionales.



Figura 13: Salida del sistema gráfico RV-MAP utilizando la bandera de activación de auditoría visual: imagen original con perímetros expandidos, izquierda, y mapa cuantitativo de costes con gradiente cónico y marcadores de posición reales, derecha

Como se documenta en la figura 13, cuando la bandera de visualización se encuentra activa, el sistema identifica los vehículos de la clase correspondiente y proyecta sus contornos mediante líneas discontinuas amarillas sobre ambos lienzos. Esto permite verificar visualmente el correcto acoplamiento entre el límite del obstáculo físico y el gradiente de coste decreciente generado a su alrededor, ofreciendo un mapa con el dato real de ocupación para agilizar las tareas logísticas del tren de arrastre o la movilización de las unidades.

Para corroborar empíricamente la utilidad operativa de esta herramienta de auditoría, la figura 14 despliega una galería de escenarios topológicos heterogéneos. En estas capturas se evidencia cómo el sistema aísla la geometría exacta de los vehículos siniestrados, superponiendo sus contornos reales sobre la matriz de transitabilidad. Esta proyección dual permite al mando táctico certificar que el algoritmo de dilatación morfológica encapsula de manera rigurosa la totalidad de la carrocería, garantizando que el gradiente de riesgo penalice los aledaños sin distorsionar la percepción del tamaño físico original del obstáculo.



a) Diseminación de vehículos en un entorno de destrucción estructural severa. El delineado audita la posición exacta de las carrocerías, confirmando que la matriz de costes absorbe el volumen físico íntegro dentro de las áreas de máxima penalización



b) Detección de maquinaria o vehículos pesados flanqueando una vía principal. La proyección de las siluetas permite al operador verificar visualmente cómo el margen cónico bloquea el paso adyacente, previniendo cuellos de botella logísticos



c) Intersección vial con múltiples vehículos bloqueando el paso. La auditoría traza el aislamiento poligonal individual de cada entidad, validando la precisión del tensor de segmentación sobre el asfalto que permanece despejado

Figura 14: Galería en columna de auditoría visual del sistema RV-MAP. Se exhibe la proyección de contornos perimetrales sobre la topología original, izquierda, y sobre la matriz de costes renderizada, derecha

5.6. Análisis de rendimiento computacional

Para satisfacer los requisitos no funcionales de eficiencia temporal definidos en la fase de análisis, el sistema debe ser capaz de operar con una latencia reducida utilizando recursos de computación móvil. Las pruebas de estrés temporal ejecutadas sobre la arquitectura hardware descrita arrojaron los siguientes tiempos de procesamiento:

- **Latencia de inferencia neuronal:** El motor de segmentación basado en YOLOv8 requiere un tiempo medio de 18.2 milisegundos por imagen utilizando la aceleración por hardware de la unidad gráfica dedicada RTX 3050 Ti.
- **Latencia de transformación:** El procesamiento de matrices, la ordenación por prioridades de capas y el cálculo de la transformada de distancia euclidiana mediante la librería NumPy añade una sobrecarga media de 10.3 milisegundos.

En conjunto, el flujo completo de procesamiento desde la entrada del fotograma hasta la exportación del mapa cuantitativo consolida una latencia total de 28.5 milisegundos por imagen. Este rendimiento equivale a una frecuencia de ejecución aproximada de 35 fotogramas por segundo, lo que valida la viabilidad técnica del software RV-MAP para ser desplegado de forma operativa en estaciones de control terrestre en tiempo real.

5.7. Análisis de Casos Límite y Falsos Positivos

El rigor exigido en la validación de un sistema orientado al soporte logístico de emergencias obliga a someter la arquitectura algorítmica a un escrutinio severo. Más allá de las métricas de precisión globales, resulta imperativo identificar, documentar y analizar aquellas casuísticas topológicas o ambientales donde la inferencia tensorial colapsa o arroja anomalías. Este análisis de casos límite (*Edge Cases*) constituye una herramienta fundamental para establecer los protocolos de seguridad del sistema, instruyendo a los operadores humanos sobre qué escenarios exigen desconfiar de la matriz de transitabilidad automatizada y recurrir a la evaluación puramente manual.

A través del procesamiento intensivo del conjunto de evaluación, se han aislado tres vectores principales de error que degradan la fidelidad geométrica de RV-MAP.

5.7.1. Interferencias lumínicas y proyecciones de sombras densas

El modelo de visión artificial procesa información estrictamente bidimensional, careciendo de la profundidad espacial que proporcionaría un sensor activo como un escáner LiDAR. Esta dependencia exclusiva de la matriz de píxeles vuelve al sistema altamente vulnerable frente a condiciones de iluminación extrema, particularmente durante las horas del amanecer o el ocaso, ángulo solar bajo.

En estos escenarios, las infraestructuras verticales que permanecen en pie proyectan sombras densas y alargadas sobre el asfalto. Al procesar estas áreas subexpuestas, la red convolucional sufre una severa pérdida de características texturales. El algoritmo tiende a interpretar erróneamente el contorno oscuro y amorfo de la sombra como una mancha de anegación hídrica o como una extensión de escombros carbonizados. Este fenómeno inyecta falsos positivos directos en la matriz de costes, obligando al módulo de enrutamiento a trazar desvíos innecesarios al catalogar como bloqueado un segmento de calzada que, físicamente, se encuentra totalmente expedito.

5.7.2. Reflejos especulares y ceguera por saturación sensorial

La detección de cuerpos de agua estancada o inundaciones representa un reto óptico mayúsculo debido a la naturaleza reflectante del medio. Cuando el UAV opera bajo un cielo despejado y el ángulo de incidencia de la luz solar coincide perpendicularmente con el eje del objetivo de la cámara, la lámina de agua actúa como un espejo.

Este rebote lumínico directo provoca una saturación abrupta en el sensor CMOS de la aeronave, quemando los píxeles y elevando los valores de los canales RGB a su límite superior, blanco puro. Al recibir este tensor sobreexpuesto, los pesos sinápticos de la arquitectura YOLOv8 fallan en la extracción de patrones geométricos, provocando una ceguera temporal. El resultado operativo es la omisión letal del obstáculo (falso negativo); el sistema renderiza la zona inundada como un espacio vacío o transitable, lo cual podría derivar en el hundimiento de un vehículo de rescate si el mando táctico aprueba la ruta sin una auditoría visual previa.

5.7.3. Variabilidad altimétrica y degradación de la escala espacial

La eficacia predictiva de las arquitecturas de aprendizaje profundo es altamente dependiente de la correspondencia dimensional entre los datos de entrenamiento y los datos de inferencia. El núcleo de RV-MAP fue entrenado asimilando ortofotos con una Distancia de Muestreo del Suelo (GSD, del inglés *Ground Sample Distance*) fuertemente acotada, propia de vuelos a baja cota.

Si en una misión de despliegue real, el operador eleva el UAV a una altitud significativamente superior para intentar mapear una avenida entera en una sola pasada, la densidad de píxeles que conforma cada objeto colapsa drásticamente. Un vehículo siniestrado que en el conjunto de entrenamiento ocupaba un bloque de 150×150 píxeles, pasa a estar representado por un cúmulo borroso de apenas 20×20 celdas. Esta contracción de la escala espacial disuelve los bordes morfológicos y las texturas críticas, provocando que la red troncal ignore por completo elementos obstructivos menores.

Para ilustrar de forma tangible estas barreras perceptivas, la figura 15 agrupa una selección de instancias donde el algoritmo ha emitido predicciones defectuosas o incompletas bajo la influencia de los estresores descritos.



a) Falso positivo inducido por contraste. La proyección de la sombra del edificio es catalogada erróneamente por la red como un obstáculo sólido bloqueando la vía



b) Partición de instancias por oclusión. Un árbol intacto divide visualmente la calzada, provocando que el algoritmo genere dos polígonos inconexos para una misma entidad de asfalto



c) Degradación por altitud excesiva. Al aumentar drásticamente la escala del plano, la red omite vehículos fragmentados cuya densidad de píxeles es residual



d) Falso negativo por ceguera lumínica. La saturación de los píxeles blancos debido al reflejo especular del sol sobre el agua impide la extracción de la silueta

Figura 15: Panel de auditoría de errores algorítmicos. Muestrario de casos límite operacionales donde las condiciones lumínicas, la escala y las oclusiones quiebran la precisión del sistema inferencial

El conocimiento exhaustivo de estas vulnerabilidades tecnológicas subraya la exigencia de establecer doctrinas de vuelo estandarizadas. Se hace indispensable dictaminar protocolos paramétricos que obliguen a los pilotos de drones a operar con bloqueos de exposición de cámara y franjas de altitud estrictas, asegurando así que la entrada de telemetría coincida métricamente con la parametrización del entorno cibernético diseñado.


5.7.4. Alucinaciones algorítmicas y límites de optimización perceptiva

A pesar de haber alcanzado una convergencia estable durante la fase de adiestramiento, el motor perceptivo opera bajo un techo de rendimiento algorítmico inherente. Al no contar con una optimización absoluta que garantice una clasificación libre de fallos en el cien por cien de los escenarios, la red neuronal convolucional sigue siendo susceptible a sufrir «alucinaciones de clase» al enfrentarse a topologías urbanas altamente ambiguas.

Uno de los errores recurrentes derivados de esta limitación operativa es la clasificación errónea de zonas transitables, así como terrenos no asfaltados o áreas que a la percepción humana se catalogan como libres, los cuales son etiquetados incorrectamente bajo la categoría de vehículos u obstáculos de máxima penalización. Este fenómeno se produce cuando un bloque de materiales destruidos, un tejado desprendido o una acumulación de troncos presenta casualmente una silueta ortogonal, proporciones espaciales o reflejos que emulan la morfología de un chasis. Al carecer de una comprensión semántica humana del contexto global, los tensores de extracción de características son engañados por esta similitud física, forzando la inyección de un halo cónico de repulsión injustificado.

Para ilustrar esta deficiencia perceptiva, la figura 16 expone una terna de ejemplos empíricos donde el sistema renderiza manchas de alto riesgo dimensional sobre entidades que, al contrastarse meticulosamente con la captura original, revelan ser simples restos inanimados o sedimentos de la catástrofe. Resulta pertinente señalar que estas instancias visuales fueron procesadas empleando puntos de control (*checkpoints*) del modelo distintos a la configuración óptima de 150 épocas. La utilización de versiones alternativas o tempranas de los tensores de inferencia evidencia cómo las configuraciones subóptimas presentan una mayor propensión a esta confusión morfológica de clases.

Aunque este tipo de falsos positivos inyecta penalizaciones redundantes en el mapa de transitabilidad, desde el punto de vista táctico resulta un fallo conservador y asumible. El sistema bloquea una zona que efectivamente contenía un obstáculo físico, escombros o árboles, priorizando la preservación de la integridad del hardware robótico y de los equipos de rescate por encima de la exactitud taxonómica estricta de la clasificación.



a) Falso positivo continuo en vía de tránsito



b) Alucinación algorítmica sobre escombros ortogonales



c) Saturación de penalización por biomasa y sombras

Figura 16: Evidencia de alucinaciones de clase provocadas por los límites de optimización perceptiva. Se contrastan fragmentos donde el modelo asigna erróneamente el grado de máxima penalización a zonas que pueden ser transitables

Capítulo 6

Conclusiones y Trabajos Futuros

El presente capítulo pone fin a la memoria del Trabajo de Fin de Grado. En la primera sección se presenta un balance general del proyecto, evaluando el grado de cumplimiento de cada uno de los objetivos propuestos al inicio de la investigación. En la segunda sección se exponen las líneas de trabajo futuro, proponiendo mejoras técnicas y evoluciones operativas que podrían derivar de los resultados obtenidos.

6.1. Consecución de los objetivos

El objetivo general de este proyecto consistía en investigar y desarrollar un sistema basado en técnicas de visión artificial para la evaluación automática de la transitabilidad del terreno tras desastres naturales. El diseño, implementación y validación del sistema RV-MAP demuestran que esta meta principal se ha alcanzado satisfactoriamente. La solución desarrollada permite transformar imágenes aéreas no estructuradas en mapas cuantitativos de costes, proporcionando una herramienta de decisión logística directa.

Para corroborar este éxito de manera rigurosa, a continuación se revisa el cumplimiento de los objetivos específicos planteados en el primer capítulo:

- **Selección de la arquitectura de red neuronal:** Se analizó el estado del arte y se seleccionó la arquitectura YOLOv8 en su variante de segmentación de instancias. Esta elección demostró ofrecer el equilibrio requerido entre precisión geométrica y eficiencia computacional, permitiendo la generación de máscaras de alta fidelidad sin penalizar los tiempos de inferencia.
- **Localización y selección del conjunto de datos:** Se investigaron diferentes repositorios públicos y se seleccionó RescueNet. Este conjunto de datos aéreos de alta resolución demostró ser el recurso idóneo para entrenar al modelo en la identificación de patrones visuales complejos propios de un entorno postdesastre.
- **Entrenamiento y clasificación de elementos críticos:** El modelo fue entrenado exitosamente para segmentar las clases prioritarias definidas en la fase de análisis. Se implementaron estrategias de ordenación y prioridad que resolvieron el solapamiento visual, garantizando la correcta clasificación de escombros, agua profunda y calzadas despejadas.

- **Diseño e implementación del algoritmo de transitabilidad:** Se cumplió con el desarrollo del núcleo del sistema. Mediante el uso de transformadas de distancia y operaciones de dilatación morfológica, se programó un algoritmo capaz de generar gradientes espaciales de peligro. Este enfoque permitió traducir las detecciones visuales en mapas de costes navegables, aplicando márgenes de seguridad estrictos alrededor de los obstáculos.
- **Evaluación del rendimiento mediante métricas estandarizadas:** El sistema fue sometido a una validación tanto cuantitativa como cualitativa. Las pruebas de rendimiento computacional confirmaron la capacidad del algoritmo para operar en frecuencias compatibles con sistemas de tiempo real, cumpliendo así con los requisitos técnicos exigidos para su despliegue operativo.

6.2. Líneas de trabajo futuro

A pesar de los resultados satisfactorios, la investigación y el desarrollo de sistemas de asistencia en catástrofes naturales es una disciplina en constante evolución. Basándose en las limitaciones identificadas durante la fase de experimentación, se proponen las siguientes líneas de trabajo futuro para continuar mejorando el sistema:

- **Integración con sistemas operativos robóticos:** El paso evolutivo natural del proyecto consiste en exportar los mapas de transitabilidad directamente a un formato compatible con marcos de trabajo estándar en robótica, tales como ROS (por sus siglas en inglés *Robot Operating System*). Esto permitiría enviar los mapas de costes en tiempo real a vehículos terrestres autónomos para que ejecuten algoritmos de enrutamiento dinámico.
- **Corrección de invariancia de escala y altitud:** Como se detectó en la fase de pruebas, la precisión del sistema disminuye si el vehículo aéreo opera a altitudes no contempladas en el entrenamiento. Una futura mejora implicaría integrar los datos de telemetría del dron, específicamente el altímetro, en el algoritmo de cálculo. De este modo, el tamaño del núcleo cónico y los márgenes de seguridad morfológicos podrían ajustarse dinámicamente en función de la altura real de vuelo.
- **Expansión a evaluación volumétrica tridimensional:** El sistema actual opera exclusivamente en un plano bidimensional. La integración de técnicas de fotogrametría geométrica o campos de radiancia neuronal permitiría extraer la altura y el volumen exacto de los escombros. Esta información tridimensional mejoraría drásticamente el cálculo del riesgo de derrumbe, refinando el gradiente de peligro de los mapas de costes.
- **Adaptación a la topología urbana nacional:** El motor perceptivo actual ha sido adiestrado utilizando el conjunto de datos RescueNet, cuyas capturas provienen de escenarios catastróficos en el continente americano. Dado que la arquitectura civil, la densidad de las infraestructuras viales y las proporciones vehiculares difieren significativamente respecto a los estándares urbanísticos de España, una línea prioritaria de desarrollo consistiría en la recolección y anotación de un corpus de datos

aéreo autóctono. Esta adaptación geográfica garantizaría que los tensores de extracción de características se ajusten fielmente a la realidad del terreno, optimizando su despliegue operativo por parte de las unidades de emergencia locales.

- **Diversificación del conjunto de datos:** Para aumentar la capacidad de generalización algorítmica, se propone reentrenar el modelo incorporando conjuntos de datos provenientes de otros tipos de catástrofes, tales como incendios forestales, terremotos o avalanchas. Un conjunto de datos más heterogéneo minimizaría el impacto de factores limitantes como las sombras extremas o los reflejos especulares, incrementando la robustez operativa del sistema bajo cualquier condición meteorológica.

Bibliografía

- [1] Gary Bradski. “The OpenCV Library”. En: *Dr. Dobb’s Journal of Software Tools* (2000) (vid. pág. 21).
- [2] Navneet Dalal y Bill Triggs. “Histograms of oriented gradients for human detection”. En: *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*. Vol. 1. 2005, págs. 886-893 (vid. pág. 5).
- [3] Milan Erdelj, Michał Król y Enrico Natalizio. “Wireless Sensor Networks and Multi-UAV systems for natural disaster management”. En: *Computer Networks* 124 (2017), págs. 72-86 (vid. págs. 2, 8).
- [4] Ross Girshick. “Fast R-CNN”. En: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2015, págs. 1440-1448 (vid. pág. 6).
- [5] Ross Girshick et al. “Rich feature hierarchies for accurate object detection and semantic segmentation”. En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2014, págs. 580-587 (vid. pág. 6).
- [6] Rafael C. Gonzalez y Richard E. Woods. *Digital Image Processing*. 4th. Pearson, 2018 (vid. pág. 5).
- [7] Ritwik Gupta et al. “Creating xBD: A dataset for assessing building damage from satellite imagery”. En: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2019 (vid. pág. 8).
- [8] Charles R Harris et al. “Array programming with NumPy”. En: *Nature* 585.7825 (2020), págs. 357-362 (vid. pág. 21).
- [9] Kaiming He, Piotr Gkioxari Georgia Dollar y Ross Girshick. “Mask R-CNN”. En: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017, págs. 2961-2969 (vid. pág. 6).
- [10] Kaiming He et al. “Deep residual learning for image recognition”. En: *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*. 2016, págs. 770-778 (vid. pág. 5).
- [11] Jefatura del Estado. *Ley 17/2015, de 9 de julio, del Sistema Nacional de Protección Civil*. BOE núm. 164, pp. 57409-57448. Jul. de 2015 (vid. pág. 1).
- [12] Glenn Jocher, Ayush Chaurasia y Jing Qiu. *Ultralytics YOLO*. <https://github.com/ultralytics/ultralytics>. [Online]. 2023 (vid. págs. 8, 14, 20).
- [13] Oussama Khatib. “Real-time obstacle avoidance for manipulators and mobile robots”. En: *The International Journal of Robotics Research* 5.1 (1986), págs. 90-98 (vid. pág. 9).

- [14] Alex Krizhevsky, Ilya Sutskever y Geoffrey E Hinton. “ImageNet classification with deep convolutional neural networks”. En: *Communications of the ACM* 60.6 (2017), págs. 84-90 (vid. pág. 5).
- [15] Hoesung Lee et al. *Climate change 2023: synthesis report. Contribution of working groups I, II and III to the sixth assessment report of the intergovernmental panel on climate change*. IPCC, Geneva, Switzerland, 2023, pág. 184 (vid. pág. 1).
- [16] Wei Liu et al. “SSD: Single shot multibox detector”. En: *European Conference on Computer Vision*. Springer. 2016, págs. 21-37 (vid. pág. 6).
- [17] Jonathan Long, Evan Shelhamer y Trevor Darrell. “Fully convolutional networks for semantic segmentation”. En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, págs. 3431-3440 (vid. pág. 6).
- [18] David G Lowe. “Distinctive image features from scale-invariant keypoints”. En: *International Journal of Computer Vision* 60.2 (2004), págs. 91-110 (vid. pág. 5).
- [19] Agencia Estatal de Meteorología. *Resumen del episodio de precipitaciones torrenciales y DANA de octubre de 2024*. Inf. téc. Madrid: Ministerio para la Transición Ecológica y el Reto Demográfico, 2024 (vid. pág. 1).
- [20] Adam Paszke et al. “PyTorch: An imperative style, high-performance deep learning library”. En: *Advances in neural information processing systems (NeurIPS)*. Vol. 32. 2019 (vid. pág. 21).
- [21] PlantText. *PlantText UML Editor*. <https://www.planttext.com/>. Accedido en el transcurso del desarrollo del proyecto. 2026 (vid. pág. 21).
- [22] Maryam Rahnemoonfar, Tashnim Chowdhury y Robin Murphy. “RescueNet: a high resolution UAV semantic segmentation dataset for natural disaster damage assessment”. En: *Scientific data* 10.1 (2023), pág. 913 (vid. págs. 9, 16).
- [23] Joseph Redmon et al. “You only look once: Unified, real-time object detection”. En: *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*. 2016, págs. 779-788 (vid. pág. 6).
- [24] Shaoqing Ren et al. “Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks”. En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 39.6 (2017), págs. 1137-1149 (vid. pág. 6).
- [25] Olaf Ronneberger, Philipp Fischer y Thomas Brox. “U-Net: Convolutional networks for biomedical image segmentation”. En: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2015, págs. 234-241 (vid. pág. 6).
- [26] Guido Van Rossum y Fred L Drake Jr. *Python tutorial*. Centrum voor Wiskunde en Informatica Amsterdam, The Netherlands, 1995 (vid. pág. 21).
- [27] Paul Viola y Michael Jones. “Rapid object detection using a boosted cascade of simple features”. En: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*. Vol. 1. 2001, págs. I-I (vid. pág. 5).

Apéndice A

Catálogo Extendido de Mapas de Transitabilidad

En este anexo se expone una batería ampliada de resultados visuales obtenidos por el sistema RV-MAP sobre capturas inéditas del conjunto de datos. El propósito de esta extensa galería es evidenciar la capacidad de generalización algorítmica frente a una alta diversidad de topologías urbanas, condiciones lumínicas y grados de destrucción estructural.

El catálogo intercala ejecuciones estándar de la matriz de transitabilidad con instancias donde se ha habilitado la herramienta de auditoría visual, delineado perimetral discontinuo. Esta exposición masiva y sin filtrar permite atestiguar la estabilidad geométrica del encapsulamiento y la robustez del cálculo de costes en un entorno operativo simulado continuo, reafirmando la viabilidad del software para su integración en vehículos no tripulados.



Figura 17: Galería extendida de validación topológica, Parte I. Muestra de mapas bidimensionales generados por el sistema, contrastando la inferencia estándar con la auditoría de vehículos



Figura 18: Galería extendida de validación topológica, Parte II

Apéndice B

Repositorio de Código y Acceso Abierto

El rigor tecnológico y la reproducibilidad algorítmica constituyen pilares fundamentales en el desarrollo de soluciones informáticas orientadas a la logística de emergencias. Con el propósito de facilitar la validación independiente, fomentar el avance de la investigación y permitir que otras entidades o equipos de rescate puedan integrar esta arquitectura en sus propios vehículos no tripulados, el código fuente íntegro del sistema RV-MAP ha sido publicado bajo una filosofía de acceso abierto.

B.1. Acceso a la plataforma computacional

El núcleo de inferencia, las rutinas de aumento de datos, los módulos de extracción de mapas de costes matriciales y los tensores de pesos preentrenados se encuentran alojados y controlados por versiones en un repositorio público. Se puede acceder a la base algorítmica mediante el siguiente identificador de red:

- **Repositorio Oficial:** <https://github.com/anuixdev/RV-MAP>
- **Documentación Técnica:** Incluida en la raíz del proyecto (README.md).

B.2. Estructura del proyecto y reproducibilidad

Para garantizar que cualquier equipo de ingeniería o de operaciones tácticas pueda instanciar el entorno en sus propias infraestructuras de cálculo, el repositorio proporciona los siguientes elementos estructurales:

- **Gestión de dependencias:** Archivos de configuración estandarizados (`requirements.txt`) que detallan las versiones exactas de las librerías matriciales y de visión artificial requeridas, asegurando la compatibilidad con los controladores de aceleración por *hardware*.

- **Módulos de ejecución paramétrica:** *Scripts* ejecutables listos para su despliegue mediante la interfaz de línea de comandos, permitiendo replicar los resultados expuestos en la presente memoria sin necesidad de alterar la lógica interna.
- **Conjunto de telemetría de prueba:** Una muestra representativa de capturas ortogonales destinada a certificar la correcta compilación y ejecución del motor de segmentación antes de procesar flujos de datos reales en el terreno.

Esta iniciativa de transparencia tecnológica busca trascender el ámbito puramente académico, transformando la red convolucional desarrollada en un recurso accesible, auditable y escalable para la comunidad internacional dedicada a la gestión de desastres naturales.